Proyecto E-commerce

Alejandra Rodríguez, Ariadna Guillio y Andrés Rodríguez

2025-09-06

1. Introducción

El comercio electrónico en Colombia ha crecido de forma acelerada, transformando la manera en que consumidores y empresas interactúan. En este contexto, resulta fundamental analizar cómo se comporta el mercado digital para identificar patrones de compra y comprender su impacto en la economía, la competitividad empresarial y los hábitos de consumo de la población. **Objetivo principal:** Diseñar, proponer e implementar soluciones y estrategias efectivas para abordar de manera integral las diferentes problemáticas identificadas, promoviendo así mejoras sostenibles, la optimización de procesos y el fortalecimiento de los objetivos institucionales o comunitarios.
Preguntas de investigación:
- ¿Que productos se compran mas online? - ¿Que departamentos compran mas online? - ¿El consumo digital ha reemplazado el fisico? - ¿El estrato socio económico está relacionado con la compra digital y física?

---

2. Búsqueda y obtención de los datos

Fuente: DANE (archivos Excel sobre comercio electrónico y ventas en valores reales).
Descripción de datos: Índice de ventas (df1) Estos datos nos indican como se comporta el comercio minorista en diferentes productos para así poder análizar cuales de estos tienen una fuerte relevancia para las ventas digitales y cuáles, por otro lado tienen una débil trazabilidad en el comercio.

```
nrow(df1)   # número de filas
```

```
## [1] 149
```

```
ncol(df1)   # número de columnas
```

```
## [1] 22
```

```
dim(df1)    # filas y columnas juntas
```

```
## [1] 149  22
```

Comercio al por menor (df2) Estos datos son importantes para analizar el alza de las ventas digitales con respecto a las físicas a lo largo del tiempo, específicamente desde 2019 hasta la actualidad. Lo cuál es de gran relevancia para nuestra investigación.

```r
nrow(df2)   # número de filas
```

```
## [1] 77
```

```r
ncol(df2)   # número de columnas
```

```
## [1] 5
```

```r
dim(df2)    # filas y columnas juntas
```

```
## [1] 77  5
```

3. Primer acercamiento (data understanding)

```r
# Primeras filas
head(df1)
```

```
## # A tibble: 6 × 22
##     Año Mes     Total comercio minorista sin otros vehí…¹ Total
comercio minor…²
##   <dbl> <chr>                                         <dbl>
<dbl>
## 1  2013 Enero                                          73.1
73.1
## 2    NA Febrero                                        70.3
68.0
## 3    NA Marzo                                          74.9
73.3
## 4    NA Abril                                          74.3
71.5
## 5    NA Mayo                                           76.3
74.7
## 6    NA Junio                                          76.5
75.3
## # ⓘ abbreviated names: ¹`Total comercio minorista sin otros
vehículos`,
## #   ²`Total comercio minorista sin vehículos`
## # ⓘ 18 more variables:
## #   `Total comercio minorista sin otros vehículos y sin combustibles`
<dbl>,
## #   `Total comercio minorista sin combustibles ni vehículos` <dbl>,
## #   `1. Alimentos (víveres en general) y bebidas no alcohólicas`
<dbl>,
## #   `2. Bebidas alcohólicas, cigarros, cigarrillos y productos del
tabaco` <dbl>, …
```

```r
head(df2)
```

```
## # A tibble: 6 × 5
##     Año Mes     `Ventas totales` Ventas realizadas a tr…¹ Ventas
realizadas a …²
```

```
##   <dbl> <chr>              <dbl>                    <dbl>
<dbl>
## 1  2019 Enero               90.7                     69.8
90.9
## 2    NA Febrero             85.3                     72.3
85.5
## 3    NA Marzo               94.7                     89.7
94.8
## 4    NA Abril               90.2                     83.5
90.3
## 5    NA Mayo                96.3                    104.
96.2
## 6    NA Junio               97.6                    101.
97.6
## # ⓘ abbreviated names: ¹`Ventas realizadas a través de comercio
electrónico`,
## #   ²`Ventas realizadas a través de canales diferentes al comercio
electrónico`
```

```
# Estadísticos generales
glimpse(df1)
```

```
## Rows: 149
## Columns: 22
## $ Año
<dbl> …
## $ Mes
<chr> …
## $ `Total comercio minorista sin otros vehículos`
<dbl> …
## $ `Total comercio minorista sin vehículos`
<dbl> …
## $ `Total comercio minorista sin otros vehículos y sin combustibles`
<dbl> …
## $ `Total comercio minorista sin combustibles ni vehículos`
<dbl> …
## $ `1. Alimentos (víveres en general) y bebidas no alcohólicas`
<dbl> …
## $ `2. Bebidas alcohólicas, cigarros, cigarrillos y productos del
tabaco`               <dbl> …
## $ `3. Prendas de vestir y textiles`
<dbl> …
## $ `4. Calzado, artículos de cuero y sucedáneos del cuero`
<dbl> …
## $ `5. Productos farmacéuticos y medicinales`
<dbl> …
## $ `6. Productos de aseo personal, cosméticos y perfumería`
<dbl> …
## $ `7. Electrodomésticos, muebles para el hogar`
<dbl> …
```

```
## $ `8. Artículos y utensilios de uso doméstico`
<dbl> …
## $ `9. Productos para el aseo del hogar`
<dbl> …
## $ `10. Equipo de informática y telecomunicaciones para uso personal o
doméstico`       <dbl> …
## $ `11. Libros, papelería, periódicos, revistas y útiles escolares`
<dbl> …
## $ `12. Artículos de ferretería, vidrios y pinturas`
<dbl> …
## $ `13. Otras mercancías para uso personal o doméstico, no
especificadas anteriormente` <dbl> …
## $ `14. Repuestos, partes, accesorios y lubricantes para vehículos`
<dbl> …
## $ `15. Combustibles para vehículos automotores`
<dbl> …
## $ `16. Vehículos automotores y motocicletas principalmente de uso de
los hogares*`     <dbl> …
```

Se puede ver que esta parte de los datos nos indica únicamente el comercio electrónico tomando como variables diferentes tipos de productos. La mayoría de os datos son numéricos de tipo double lo cual es bastante útil para nosotros al momento de graficar. De esta dataset se espera encontrar productos con una venta electrónica alta y baja para identificar puntos débiles y fuertes.

```
glimpse(df2)
```

```
## Rows: 77
## Columns: 5
## $ Año
<dbl> …
## $ Mes
<chr> …
## $ `Ventas totales`
<dbl> …
## $ `Ventas realizadas a través de comercio electrónico`
<dbl> …
## $ `Ventas realizadas a través de canales diferentes al comercio
electrónico` <dbl> …
```

Estos datos nos muestran como se comportna el comercio electrónico y el físico con el paso del tiempo. La mayoría de los datos en este dataset tambien son numéricos de tipo double y con esto se espera analizar qué comercio tiene mayor impacto en la actualidad para la economía colombiana teniendo en cuenta su evolución temporal.

4. Limpieza y preparación de datos

Al ser una base de datos del DANE, está bastante ordenada y limpia desde el principio por lo cual, en esta sección reemplazaremos datos nulos para df1.

```
# Estadísticas descriptivas
summary(df1)
```

```
##       Año           Mes            Total comercio minorista sin otros
vehículos
##  Min.   :2013   Length:149         Min.   : 55.46
##  1st Qu.:2016   Class :character   1st Qu.: 85.60
##  Median :2019   Mode  :character   Median : 92.83
##  Mean   :2019                      Mean   : 98.68
##  3rd Qu.:2022                      3rd Qu.:111.91
##  Max.   :2025                      Max.   :154.05
##  NA's   :136
##  Total comercio minorista sin vehículos
##  Min.   : 61.19
##  1st Qu.: 85.29
##  Median : 93.01
##  Mean   : 98.56
##  3rd Qu.:111.70
##  Max.   :155.86
##
##  Total comercio minorista sin otros vehículos y sin combustibles
##  Min.   : 58.30
##  1st Qu.: 83.80
##  Median : 92.92
##  Mean   : 98.67
##  3rd Qu.:112.13
##  Max.   :163.49
##
##  Total comercio minorista sin combustibles ni vehículos
##  Min.   : 65.20
##  1st Qu.: 83.44
##  Median : 94.88
##  Mean   : 98.54
##  3rd Qu.:112.46
##  Max.   :167.29
##
##  1. Alimentos (víveres en general) y bebidas no alcohólicas
##  Min.   : 64.54
##  1st Qu.: 81.49
##  Median : 96.68
##  Mean   : 93.38
##  3rd Qu.:103.88
##  Max.   :133.23
##
##  2. Bebidas alcohólicas, cigarros, cigarrillos y productos del tabaco
```

```
##  Min.   : 44.40
##  1st Qu.: 70.04
##  Median : 83.99
##  Mean   :100.93
##  3rd Qu.:118.59
##  Max.   :310.14
##
##  3. Prendas de vestir y textiles
##  Min.   :  9.047
##  1st Qu.: 70.478
##  Median : 84.274
##  Mean   : 96.301
##  3rd Qu.:101.201
##  Max.   :304.551
##
##  4. Calzado, artículos de cuero y sucedáneos del cuero
##  Min.   :  7.347
##  1st Qu.: 75.976
##  Median : 86.794
##  Mean   : 98.402
##  3rd Qu.:105.899
##  Max.   :287.562
##
##  5. Productos farmacéuticos y medicinales
##  Min.   : 82.07
##  1st Qu.: 97.27
##  Median :101.55
##  Mean   :101.87
##  3rd Qu.:105.79
##  Max.   :129.95
##
##  6. Productos de aseo personal, cosméticos y perfumería
##  Min.   : 75.76
##  1st Qu.: 90.38
##  Median : 99.08
##  Mean   :103.37
##  3rd Qu.:117.43
##  Max.   :159.29
##
##  7. Electrodomésticos, muebles para el hogar
##  Min.   : 41.23
##  1st Qu.: 89.32
##  Median : 99.52
##  Mean   :105.51
##  3rd Qu.:118.71
##  Max.   :179.80
##
##  8. Artículos y utensilios de uso doméstico 9. Productos para el aseo
del hogar
##  Min.   : 39.68                              Min.   : 59.39
```

```
##  1st Qu.: 84.63                                1st Qu.: 77.94
##  Median : 97.22                                Median : 97.18
##  Mean   :106.08                                Mean   :101.24
##  3rd Qu.:125.64                                3rd Qu.:124.93
##  Max.   :214.82                                Max.   :160.94
##
##  10. Equipo de informática y telecomunicaciones para uso personal o
doméstico
##  Min.   : 39.03
##  1st Qu.: 62.16
##  Median : 93.85
##  Mean   :106.33
##  3rd Qu.:141.50
##  Max.   :270.17
##
##  11. Libros, papelería, periódicos, revistas y útiles escolares
##  Min.   : 24.83
##  1st Qu.: 76.31
##  Median : 85.38
##  Mean   :102.45
##  3rd Qu.:106.15
##  Max.   :270.40
##
##  12. Artículos de ferretería, vidrios y pinturas
##  Min.   : 25.43
##  1st Qu.: 91.43
##  Median : 99.77
##  Mean   :100.02
##  3rd Qu.:108.84
##  Max.   :135.81
##
##  13. Otras mercancías para uso personal o doméstico, no especificadas
anteriormente
##  Min.   : 52.79
##  1st Qu.: 74.29
##  Median : 88.35
##  Mean   : 97.02
##  3rd Qu.:111.22
##  Max.   :196.02
##
##  14. Repuestos, partes, accesorios y lubricantes para vehículos
##  Min.   : 28.70
##  1st Qu.: 96.96
##  Median :103.70
##  Mean   :104.44
##  3rd Qu.:114.02
##  Max.   :129.28
##
##  15. Combustibles para vehículos automotores
##  Min.   : 45.17
```

```
##  1st Qu.: 92.28
##  Median : 98.22
##  Mean   : 99.83
##  3rd Qu.:110.17
##  Max.   :123.56
##
##  16. Vehículos automotores y motocicletas principalmente de uso de los
hogares*
##  Min.   :  5.057
##  1st Qu.: 87.339
##  Median : 96.120
##  Mean   : 99.024
##  3rd Qu.:110.252
##  Max.   :147.480
##

# Contar valores NA por columna
colSums(is.na(df1))

##
Año
##
136
##
Mes
##
0
##                                        Total comercio minorista sin
otros vehículos
##
0
##                                              Total comercio minorista
sin vehículos
##
0
##                    Total comercio minorista sin otros vehículos y sin
combustibles
##
0
##                               Total comercio minorista sin combustibles
ni vehículos
##
0
##                          1. Alimentos (víveres en general) y bebidas no
alcohólicas
##
0
##                2. Bebidas alcohólicas, cigarros, cigarrillos y
productos del tabaco
##
```

```
0
##                                                    3. Prendas de
vestir y textiles
##
0
##                              4. Calzado, artículos de cuero y
sucedáneos del cuero
##
0
##                                          5. Productos farmacéuticos y
medicinales
##
0
##                             6. Productos de aseo personal, cosméticos
y perfumería
##
0
##                                       7. Electrodomésticos, muebles
para el hogar
##
0
##                                        8. Artículos y utensilios de
uso doméstico
##
0
##                                              9. Productos para el
aseo del hogar
##
0
##       10. Equipo de informática y telecomunicaciones para uso personal
o doméstico
##
0
##                     11. Libros, papelería, periódicos, revistas y
útiles escolares
##
0
##                                    12. Artículos de ferretería,
vidrios y pinturas
##
0
## 13. Otras mercancías para uso personal o doméstico, no especificadas
anteriormente
##
0
##                     14. Repuestos, partes, accesorios y lubricantes
para vehículos
##
0
##                                       15. Combustibles para vehículos
```

```
automotores
##
0
##     16. Vehículos automotores y motocicletas principalmente de uso de
los hogares*
##
0

# Rellenar NA con forward fill
df1 <- df1 %>%
  fill(everything(), .direction = "down")

# Verificar de nuevo
colSums(is.na(df1))

##
Año
##
0
##
Mes
##
0
##                                        Total comercio minorista sin
otros vehículos
##
0
##                                              Total comercio minorista
sin vehículos
##
0
##                     Total comercio minorista sin otros vehículos y sin
combustibles
##
0
##                               Total comercio minorista sin combustibles
ni vehículos
##
0
##                           1. Alimentos (víveres en general) y bebidas no
alcohólicas
##
0
##                2. Bebidas alcohólicas, cigarros, cigarrillos y
productos del tabaco
##
0
##                                                        3. Prendas de
vestir y textiles
##
```

0
4. Calzado, artículos de cuero y sucedáneos del cuero
##
0
5. Productos farmacéuticos y medicinales
##
0
6. Productos de aseo personal, cosméticos y perfumería
##
0
7. Electrodomésticos, muebles para el hogar
##
0
8. Artículos y utensilios de uso doméstico
##
0
9. Productos para el aseo del hogar
##
0
10. Equipo de informática y telecomunicaciones para uso personal o doméstico
##
0
11. Libros, papelería, periódicos, revistas y útiles escolares
##
0
12. Artículos de ferretería, vidrios y pinturas
##
0
13. Otras mercancías para uso personal o doméstico, no especificadas anteriormente
##
0
14. Repuestos, partes, accesorios y lubricantes para vehículos
##
0
15. Combustibles para vehículos automotores
##
0
16. Vehículos automotores y motocicletas principalmente de uso de

```
los hogares*
##
0
```

```
head(df1, 10)
```

```
## # A tibble: 10 × 22
##      Año Mes        Total comercio minorista sin otros …¹ Total
comercio minor…²
##    <dbl> <chr>                                        <dbl>
<dbl>
##  1  2013 Enero                                         73.1
73.1
##  2  2013 Febrero                                       70.3
68.0
##  3  2013 Marzo                                         74.9
73.3
##  4  2013 Abril                                         74.3
71.5
##  5  2013 Mayo                                          76.3
74.7
##  6  2013 Junio                                         76.5
75.3
##  7  2013 Julio                                         80.7
77.7
##  8  2013 Agosto                                        78.4
76.4
##  9  2013 Septiembre                                    76.0
73.2
## 10  2013 Octubre                                       78.7
75.8
## # ⓘ abbreviated names: ¹`Total comercio minorista sin otros
vehículos`,
## #   ²`Total comercio minorista sin vehículos`
## # ⓘ 18 more variables:
## #   `Total comercio minorista sin otros vehículos y sin combustibles`
<dbl>,
## #   `Total comercio minorista sin combustibles ni vehículos` <dbl>,
## #   `1. Alimentos (víveres en general) y bebidas no alcohólicas`
<dbl>,
## #   `2. Bebidas alcohólicas, cigarros, cigarrillos y productos del
tabaco` <dbl>, …
```

```
head(df1)
```

```
## # A tibble: 6 × 22
##     Año Mes     Total comercio minorista sin otros vehí…¹ Total
comercio minor…²
##   <dbl> <chr>                                        <dbl>
<dbl>
## 1  2013 Enero                                         73.1
```

```
73.1
## 2  2013 Febrero                                          70.3
68.0
## 3  2013 Marzo                                            74.9
73.3
## 4  2013 Abril                                            74.3
71.5
## 5  2013 Mayo                                             76.3
74.7
## 6  2013 Junio                                            76.5
75.3
## # ℹ abbreviated names: ¹`Total comercio minorista sin otros
vehículos`,
## #   ²`Total comercio minorista sin vehículos`
## # ℹ 18 more variables:
## #   `Total comercio minorista sin otros vehículos y sin combustibles`
<dbl>,
## #   `Total comercio minorista sin combustibles ni vehículos` <dbl>,
## #   `1. Alimentos (víveres en general) y bebidas no alcohólicas`
<dbl>,
## #   `2. Bebidas alcohólicas, cigarros, cigarrillos y productos del
tabaco` <dbl>, …
```

En esta sección reemplazaremos datos nulos para df2, los cuales en su mayoría se encuentran en la columna “Año”, lo que se piensa hacer es ubicar el año correspondiente en cada fila del mes ya que inicialmente solo aparece en la primera fila de cada año .

```
# Estadísticas descriptivas
summary(df2)
```

```
##       Año           Mes            Ventas totales
##  Min.   :2019   Length:77          Min.   : 65.21
##  1st Qu.:2020   Class :character   1st Qu.:100.04
##  Median :2022   Mode  :character   Median :132.87
##  Mean   :2022                      Mean   :129.66
##  3rd Qu.:2024                      3rd Qu.:152.78
##  Max.   :2025                      Max.   :214.86
##  NA's   :70
##  Ventas realizadas a través de comercio electrónico
##  Min.   : 69.85
##  1st Qu.:211.32
##  Median :250.38
##  Mean   :255.08
##  3rd Qu.:292.17
##  Max.   :537.66
##
##  Ventas realizadas a través de canales diferentes al comercio
electrónico
##  Min.   : 61.61
##  1st Qu.:100.17
```

```
##  Median :131.54
##  Mean   :128.04
##  3rd Qu.:151.14
##  Max.   :212.35
##
```

```
# Contar valores NA por columna
colSums(is.na(df2))
```

```
##
Año
##
70
##
Mes
##
0
##                                                                Ventas
totales
##
0
##                        Ventas realizadas a través de comercio
electrónico
##
0
## Ventas realizadas a través de canales diferentes al comercio
electrónico
##
0
```

```
# Rellenar NA con forward fill
df2 <- df2 %>%
  fill(everything(), .direction = "down")

# Verificar de nuevo
colSums(is.na(df2))
```

```
##
Año
##
0
##
Mes
##
0
##                                                                Ventas
totales
##
0
##                        Ventas realizadas a través de comercio
electrónico
```

```
##
0
## Ventas realizadas a través de canales diferentes al comercio
electrónico
##
0
```

```
head(df2, 10)
```

```
## # A tibble: 10 × 5
##      Año Mes      `Ventas totales` Ventas realizadas a …¹ Ventas
realizadas a …²
##    <dbl> <chr>              <dbl>                  <dbl>
<dbl>
##  1  2019 Enero               90.7                   69.8
90.9
##  2  2019 Febrero             85.3                   72.3
85.5
##  3  2019 Marzo               94.7                   89.7
94.8
##  4  2019 Abril               90.2                   83.5
90.3
##  5  2019 Mayo                96.3                  104.
96.2
##  6  2019 Junio               97.6                  101.
97.6
##  7  2019 Julio              100.                    90.4
100.
##  8  2019 Agosto             102.                    93.9
102.
##  9  2019 Septiem…            98.0                   90.9
98.1
## 10  2019 Octubre            101.                   116.
100.
## # ⓘ abbreviated names: ¹`Ventas realizadas a través de comercio
electrónico`,
## #   ²`Ventas realizadas a través de canales diferentes al comercio
electrónico`
```

```
head(df2)
```

```
## # A tibble: 6 × 5
##     Año Mes     `Ventas totales` Ventas realizadas a tr…¹ Ventas
realizadas a …²
##   <dbl> <chr>             <dbl>                   <dbl>
<dbl>
## 1  2019 Enero              90.7                    69.8
90.9
## 2  2019 Febrero            85.3                    72.3
85.5
## 3  2019 Marzo              94.7                    89.7
```

```
94.8
## 4  2019 Abril               90.2                    83.5
90.3
## 5  2019 Mayo                96.3                   104.
96.2
## 6  2019 Junio               97.6                   101.
97.6
## # ⓘ abbreviated names: ¹`Ventas realizadas a través de comercio
electrónico`,
## #   ²`Ventas realizadas a través de canales diferentes al comercio
electrónico`
```

En este caso en la limpieza, para ninguna de las bases de datos fue necesario promediar y llenar celdas vacías con la media.

Detección de outliers Inicialmente cambiaremos las variables que detectamos con un tipo de variablepara ambas bases de datos, por ejemplo año que debería ser numérico de tipo int o mes que debería ser una fecha, entonces finalmente se creó una nueva columna con las fechas en DD/MM/AAAA.

```r
library(lubridate)

# df1
df1 <- df1 %>%
  mutate(
    Año = as.integer(Año),
    Mes = match(Mes, c("Enero","Febrero","Marzo","Abril","Mayo","Junio",

"Julio","Agosto","Septiembre","Octubre","Noviembre","Diciembre")),
    Fecha = make_date(year = Año, month = Mes, day = 1)
  )
df1 <- df1 %>%
  mutate(
    Año = as.integer(Año),
    Fecha = dmy(paste("01", Mes, Año))
  )

# df2
df2 <- df2 %>%
  mutate(
    Año = as.integer(Año),
    Mes = match(Mes, c("Enero","Febrero","Marzo","Abril","Mayo","Junio",

"Julio","Agosto","Septiembre","Octubre","Noviembre","Diciembre")),
    Fecha = make_date(year = Año, month = Mes, day = 1)
  )
df2 <- df2 %>%
  mutate(
    Año = as.integer(Año),
    Fecha = dmy(paste("01", Mes, Año))
```

```
  )

glimpse(df1)
```

```
## Rows: 149
## Columns: 23
## $ Año
<int> …
## $ Mes
<int> …
## $ `Total comercio minorista sin otros vehículos`
<dbl> …
## $ `Total comercio minorista sin vehículos`
<dbl> …
## $ `Total comercio minorista sin otros vehículos y sin combustibles`
<dbl> …
## $ `Total comercio minorista sin combustibles ni vehículos`
<dbl> …
## $ `1. Alimentos (víveres en general) y bebidas no alcohólicas`
<dbl> …
## $ `2. Bebidas alcohólicas, cigarros, cigarrillos y productos del
tabaco`               <dbl> …
## $ `3. Prendas de vestir y textiles`
<dbl> …
## $ `4. Calzado, artículos de cuero y sucedáneos del cuero`
<dbl> …
## $ `5. Productos farmacéuticos y medicinales`
<dbl> …
## $ `6. Productos de aseo personal, cosméticos y perfumería`
<dbl> …
## $ `7. Electrodomésticos, muebles para el hogar`
<dbl> …
## $ `8. Artículos y utensilios de uso doméstico`
<dbl> …
## $ `9. Productos para el aseo del hogar`
<dbl> …
## $ `10. Equipo de informática y telecomunicaciones para uso personal o
doméstico`       <dbl> …
## $ `11. Libros, papelería, periódicos, revistas y útiles escolares`
<dbl> …
## $ `12. Artículos de ferretería, vidrios y pinturas`
<dbl> …
## $ `13. Otras mercancías para uso personal o doméstico, no
especificadas anteriormente` <dbl> …
## $ `14. Repuestos, partes, accesorios y lubricantes para vehículos`
<dbl> …
## $ `15. Combustibles para vehículos automotores`
<dbl> …
## $ `16. Vehículos automotores y motocicletas principalmente de uso de
los hogares*`     <dbl> …
```

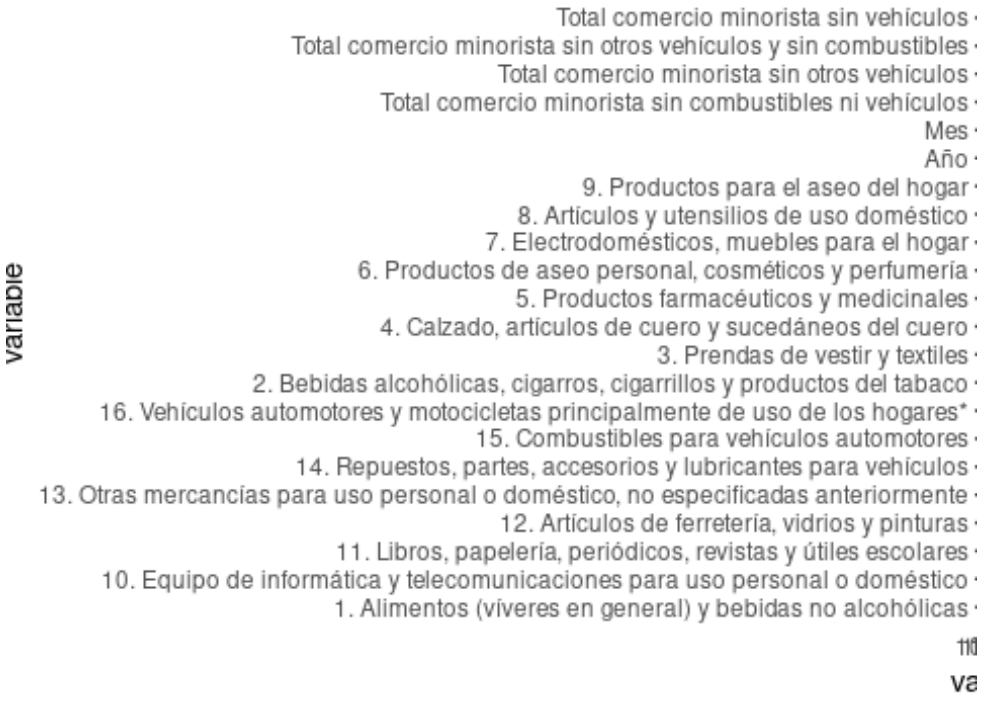
```
## $ Fecha
<date> …
```

```
glimpse(df2)
```

```
## Rows: 77
## Columns: 6
## $ Año
<int> …
## $ Mes
<int> …
## $ `Ventas totales`
<dbl> …
## $ `Ventas realizadas a través de comercio electrónico`
<dbl> …
## $ `Ventas realizadas a través de canales diferentes al comercio
electrónico` <dbl> …
## $ Fecha
<date> …
```

Para identificar datos atípicos usaremos

```
df1 %>%
  select(where(is.numeric)) %>%
  pivot_longer(everything(), names_to = "variable", values_to = "valor")
%>%
  ggplot(aes(x = variable, y = valor)) +
  geom_boxplot(outlier.color = "red") +
  scale_y_log10() +   # escala logarítmica
  coord_flip() +
  labs(title = "Outliers en escala logarítmica")
```



Usamos esta gráfica para ver de forma clara la dispersión de las ventas electrónicas de los diferentes productos. En el código se hizo uso de una escala logarítmica debido a que hay algunos valores demasiado grandes en comparación con otros lo cuál vuelve más dificil analizar los outliers de todos los productos en un mismo gráfico. Con base a la gáfica podemos deducir que la mayoría de productos cuentan con alzas y caídas en sus ventas, sin embargo, al ser un boxplot no tenemos trazabilidad temporal para sacar una justificación a dichas dispersiones, sin embargo se deduce que la mayoría de estas dispersiones son debidas a la pandemia del covid-19 en 2020.

5. Normalización y estandarización de datos

A continuación, escogeremos diferentes variables numéricas de las dos bases de datos para hacer la estandarización de datos, la cual es parte vital de nuestro preprocesamiento de los datos. La idea es convertir los valores en un rango [0,1] a través de la fórmula {x' = (x - min(x))/(max(x) - min(x))} En df1 y df2 la mayoría de los datos son numéricos como se mencionó anteriormente, por lo cual se usará una función para transformar todos los datos numéricos.

```
# df1
normalize_minmax <- function(x) {
  (x - min(x, na.rm = TRUE)) / (max(x, na.rm = TRUE) - min(x, na.rm =
TRUE))
}
```

```r
df1_norm <- df1 %>%
  mutate(across(where(is.numeric), normalize_minmax))

#df2
normalize_minmax <- function(x) {
  (x - min(x, na.rm = TRUE)) / (max(x, na.rm = TRUE) - min(x, na.rm =
TRUE))
}

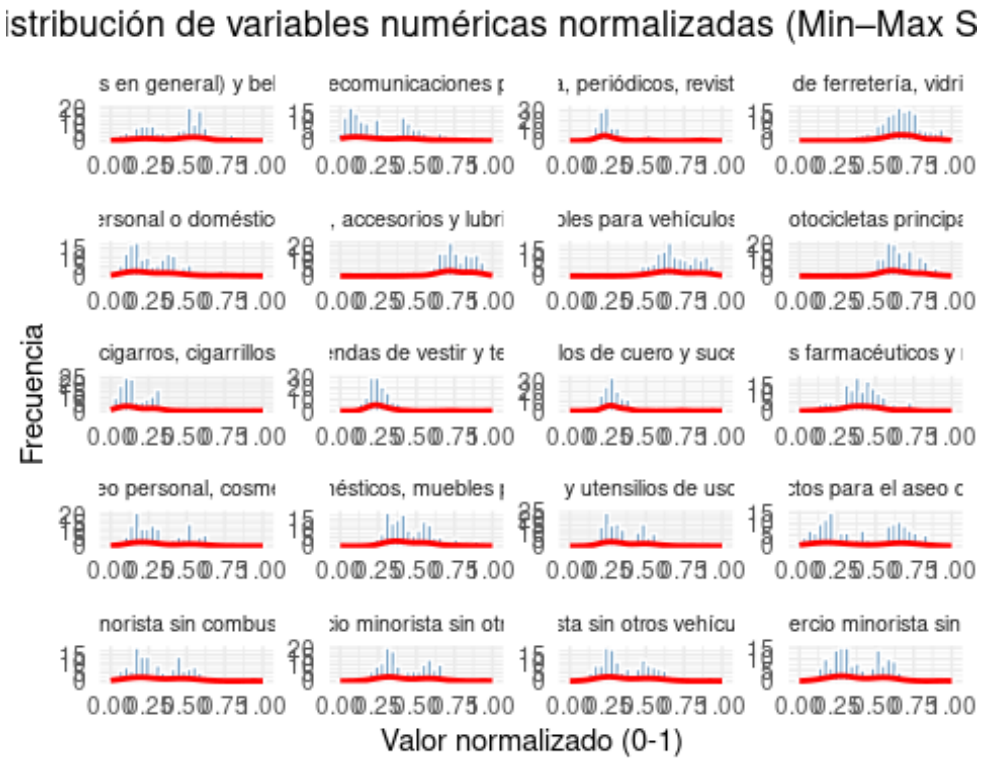
df2_norm <- df2 %>%
  mutate(across(where(is.numeric), normalize_minmax))
```

A continuación se realizarán graficas de las distribuciones para normalizadas y estandarizadas con df1 y df2 y así analizar el comportamiento de las variables con ambas técnicas y así identificar la mitigación de sesgos.

Grafica para df1:

```r
df1_norm_long <- df1_norm %>%
  select(-Año, -Mes, -Fecha) %>%
  pivot_longer(everything(), names_to = "Variable", values_to = "Valor")

ggplot(df1_norm_long, aes(x = Valor)) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white", alpha =
0.7) +
  geom_density(color = "red", size = 1, alpha = 0.5) +
  facet_wrap(~ Variable, scales = "free", ncol = 4) +   # 4 columnas en
vez de todo apilado
  labs(title = "Distribución de variables numéricas normalizadas (Min-Max
Scaling)",
       x = "Valor normalizado (0-1)",
       y = "Frecuencia") +
  theme_minimal() +
  theme(strip.text = element_text(size = 8),   # nombres más pequeños
        plot.title = element_text(hjust = 0.5))
```

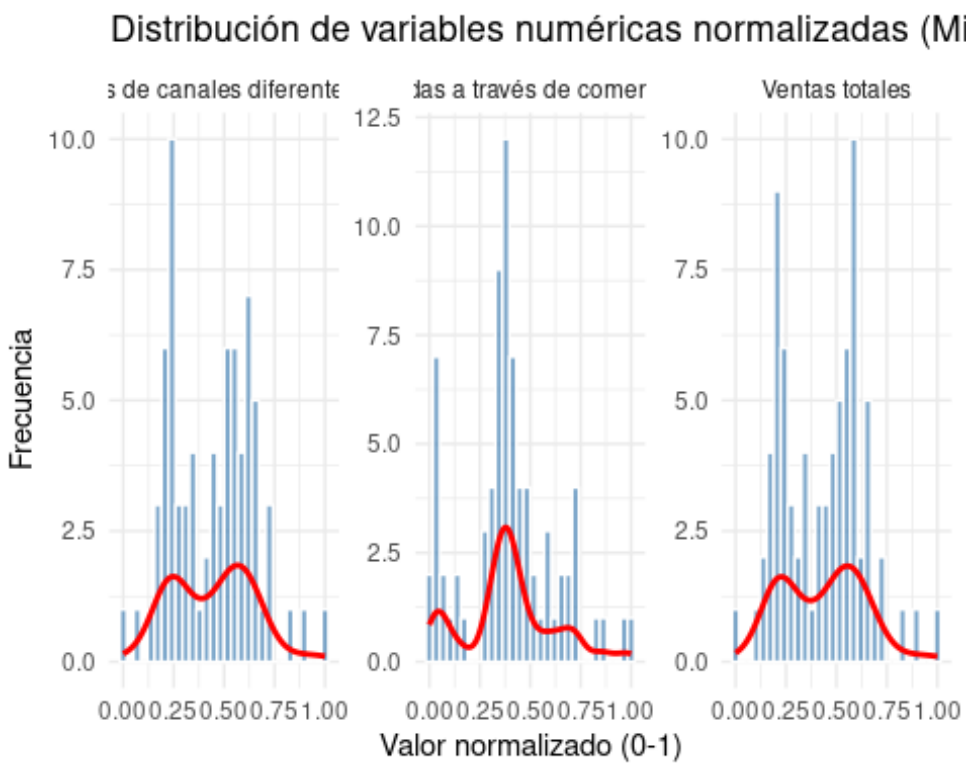


Gráfica para df2:

```
library(ggplot2)
library(dplyr)
library(tidyr)

# Pivotear solo variables numéricas que no sean Año ni Mes
df2_norm_long <- df2_norm %>%
  select(-Año, -Mes, -Fecha) %>%   # quitamos columnas que no queremos
  pivot_longer(everything(), names_to = "Variable", values_to = "Valor")

# Graficar distribución
ggplot(df2_norm_long, aes(x = Valor)) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white", alpha =
0.7) +
  geom_density(color = "red", size = 1, alpha = 0.5) +
  facet_wrap(~ Variable, scales = "free", ncol = 3) +
  labs(title = "Distribución de variables numéricas normalizadas (Min-Max
Scaling)",
       x = "Valor normalizado (0-1)",
       y = "Frecuencia") +
  theme_minimal()
```



De ambas gráficas podemos ver que efectivamente todas las variables fueron transformadas a un rango [0,1] con el fin que poder compararlas entre ellas y que estén en igualdad de condiciones ya que en este caso no se tienen en cuenta las magnitudes originales. Específicamente para df1,

Ahora se hará la estandarización con Z-score scaling para convertir la media en 0 y la desviación estándar en 1 a través de la fórmula {x'= (x−μ)/σ}

```
#df1
df1_std <- df1 %>%
  mutate(across(where(is.numeric), scale))

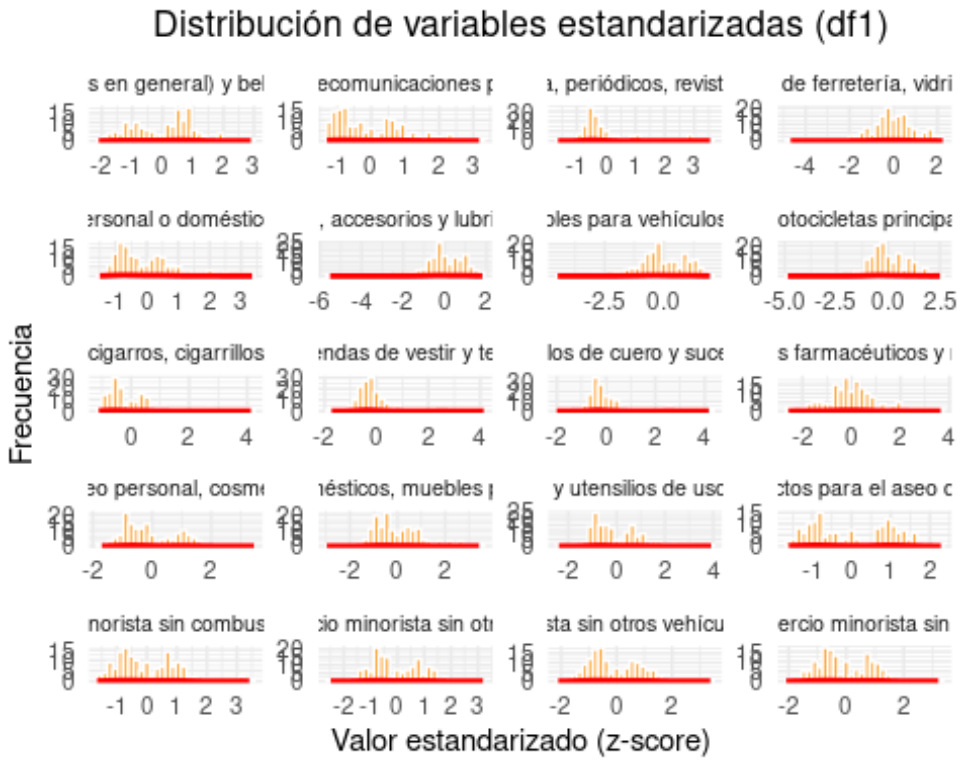
#df2
df2_std <- df2 %>%
  mutate(across(where(is.numeric), scale))
```

Grafica para df1:

```
df1_std_long <- df1_std %>%
  select(where(is.numeric), -Año, -Mes) %>%   # quitamos variables no
relevantes
  pivot_longer(cols = everything(), names_to = "Variable", values_to =
"Valor")

ggplot(df1_std_long, aes(x = Valor)) +
  geom_histogram(bins = 30, fill = "darkorange", color = "white", alpha =
0.7) +
```

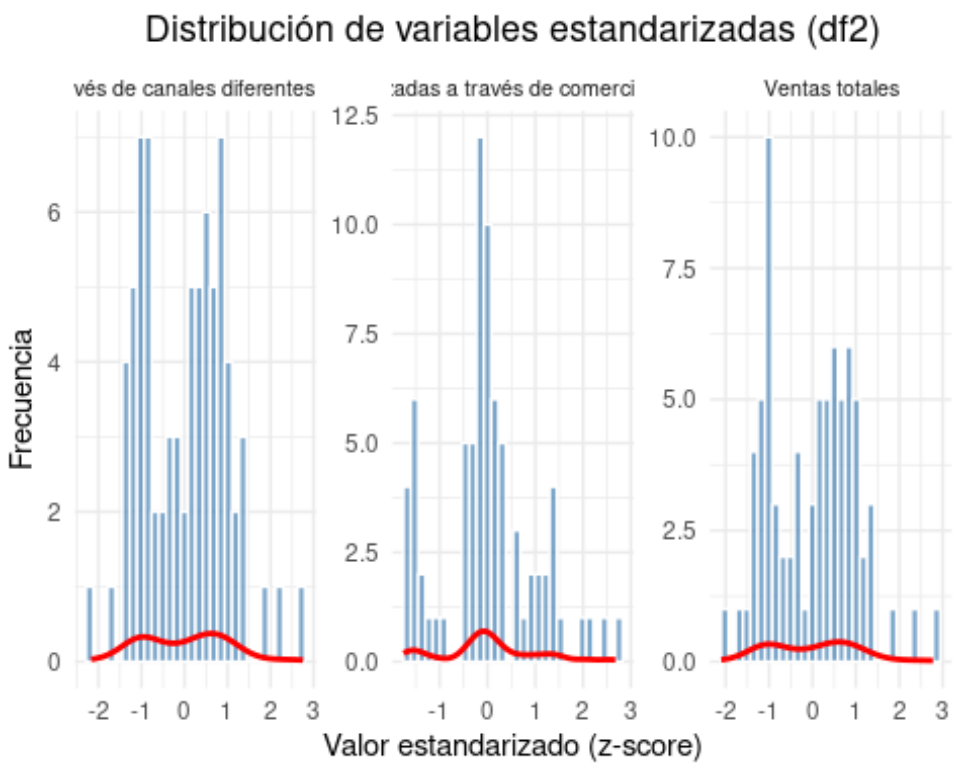
```
  geom_density(color = "red", size = 1, alpha = 0.6) +
  facet_wrap(~ Variable, scales = "free", ncol = 4) +
  labs(title = "Distribución de variables estandarizadas (df1)",
       x = "Valor estandarizado (z-score)", y = "Frecuencia") +
  theme_minimal() +
  theme(strip.text = element_text(size = 8),
        plot.title = element_text(hjust = 0.5))
```



Gráfica para df2:

```
df2_std_long <- df2_std %>%
  select(where(is.numeric), -Año, -Mes) %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to =
"Valor")

ggplot(df2_std_long, aes(x = Valor)) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white", alpha =
0.7) +
  geom_density(color = "red", size = 1, alpha = 0.6) +
  facet_wrap(~ Variable, scales = "free", ncol = 4) +
  labs(title = "Distribución de variables estandarizadas (df2)",
       x = "Valor estandarizado (z-score)", y = "Frecuencia") +
  theme_minimal() +
  theme(strip.text = element_text(size = 8),
        plot.title = element_text(hjust = 0.5))
```



Finalmente se compara el antes y el después de los datos tratados

```
 # Antes df1
summary(df1$`Total comercio minorista sin otros vehículos`)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   55.46   85.60   92.83   98.68  111.91  154.05
```

```
sd(df1$`Total comercio minorista sin otros vehículos`, na.rm = TRUE)
```

```
## [1] 17.384
```

```
 # Antes df2
summary(df2$`Ventas totales`)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   65.21  100.04  132.87  129.66  152.78  214.86
```

```
sd(df2$`Ventas totales`, na.rm = TRUE)
```

```
## [1] 30.68743
```

```
 # Después de la Normalización df1
summary(df1_norm$`Total comercio minorista sin otros vehículos`)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  0.0000  0.3057  0.3790  0.4383  0.5726  1.0000
```

```
sd(df1_norm$`Total comercio minorista sin otros vehículos`, na.rm = TRUE)
```

```
## [1] 0.1763294
```

```
 # Después de la Normalización df2
summary(df2_norm$`Ventas realizadas a través de comercio electrónico`)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  0.0000  0.3024  0.3859  0.3960  0.4752  1.0000
```

```
sd(df2_norm$`Ventas totales`, na.rm = TRUE)
```

```
## [1] 0.2050684
```

```
 # Después de la Estandarización df1
summary(df1_std$`Total comercio minorista sin otros vehículos`)
```

```
##        V1
##  Min.   :-2.4859
##  1st Qu.:-0.7522
##  Median :-0.3368
##  Mean   : 0.0000
##  3rd Qu.: 0.7613
##  Max.   : 3.1853
```

```
sd(df1_std$`Total comercio minorista sin otros vehículos`, na.rm = TRUE)
```

```
## [1] 1
```

```
# Después de la Estandarización df1
summary(df2_std$`Ventas realizadas a través de comercio electrónico`)
```

```
##        V1
##  Min.   :-1.75531
##  1st Qu.:-0.41471
##  Median :-0.04455
##  Mean   : 0.00000
##  3rd Qu.: 0.35150
##  Max.   : 2.67778
```

```
sd(df2_std$`Ventas realizadas a través de comercio electrónico`, na.rm =
TRUE)
```

```
## [1] 1
```

En la normalización de los datos, antes habían valores muy grandes con una desviación estándar de 17.343 para df1 y 30.68743 para df2, después los valores quedaron transformados en el rango anteriormente mencionado ([0,1]) y gracias a ello, la desviación estándar bajó a valores de o.1763294 para df1 y de 0.2050684 para df2. Lo que significa que gracias a la normalización, todas las variables numéricas se comparan en proporciones sin importar sus magnitudes anteriores. Luego, en la estandarización, las variables de ambas bases de datos tenían medidas distintas y desviaciones muy grandes, después de estandarizarlas la media se transformó a 0 como se esperaba y así mismo, la desviación estándar se volvió en 1, lo cuál nos indica que fue correcto el proceso que se

hizo y también que los datos se midieron en unidades de desviación para así poder compararlas en una distribución normal.

#6. Análisis exploratorio básico (EDA) El siguiente paso consiste en seleccionar dos variables representativas de cada base de datos (df1 y df2) con el objetivo de realizar un análisis estadístico descriptivo más profundo. Este análisis nos permitirá entender la distribución, la tendencia central y la dispersión de las variables seleccionadas, así como identificar posibles patrones, outliers o relaciones significativas.

```
# Tendencia central df1
Media <- mean(df1_norm$`Total comercio minorista sin otros vehículos`)
Media

## [1] 0.4383402
```

Tras aplicar anteriormente una normalizacion de los datos a la variable “Total comercio minorista sin otros vehículos”, tenemos como resultado una media de 0.4383402 esto quiere decir que el comportamiento general de la variable se sitúa alrededor del 43% de la magnitud máxima observada, por esta razon la tendencia es mas cercana a los valores bajos.

```
Mediana <- median(df1_norm$`Total comercio minorista sin otros
vehículos`)
Mediana

## [1] 0.3789522
```

Al obtener una mediana normalizada de 0.3789522 podemos decir que el 50% de los datos maximos se encuentran por debajo del 38% del rango maximo posible. Esto nos ayuda a confirmar que la concentración de los valores se encuentran en la parte baja–media de la distribución

```
moda <- function(x) {
  ux <- unique(x)
  ux[which.max(tabulate(match(x, ux)))]
}
moda(df1_norm$`Total comercio minorista sin otros vehículos`)

## [1] 0.1785147
```

La moda de la variable normalizada es 0.1763294, esto quiere decir que el valor más frecuente se ubica en el 18% del rango máximo.

```
Cuartiles <- quantile(df1_norm$`Total comercio minorista sin otros
vehículos`, probs = c(0.25, 0.5, 0.75), na.rm = TRUE)
Cuartiles

##       25%       50%       75%
## 0.3057092 0.3789522 0.5725761
```

Teniendo en cuenta que los valores de los datos estan normalizados podemos decir que el valor que marca el primer 25% es 0.3057092, la media de es el valor 0.3789522 y el valor por debajo del cual se encuentra el 75% de los datos es 0.5725761

```
Varianza <- var(df1_norm$`Total comercio minorista sin otros vehículos`)
Varianza
```

```
## [1] 0.03109205
```

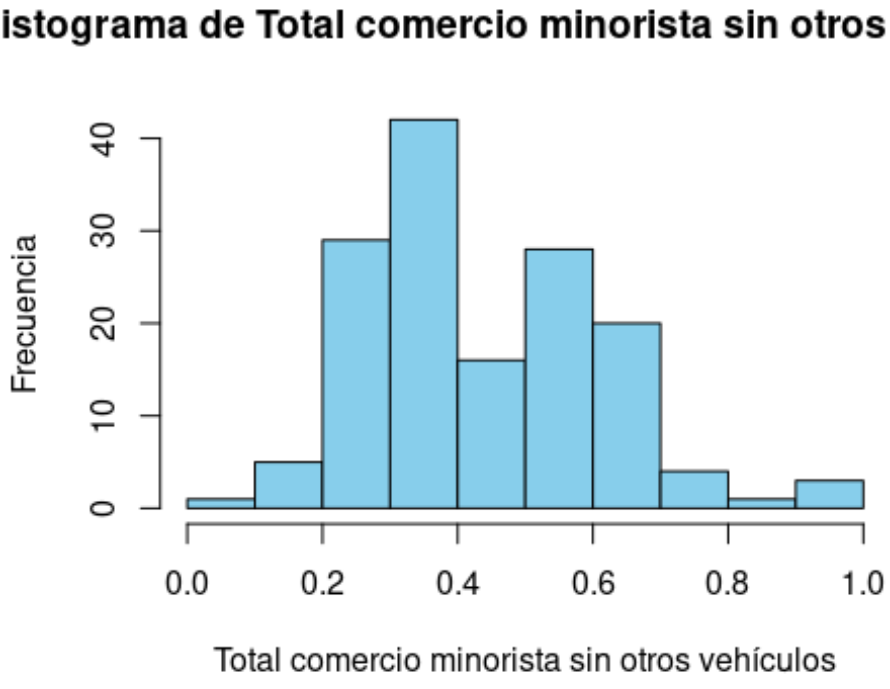
La dispersion presente en los datos normalizados al promedio del conjunto es de 0.03109205

```
Desviacion <- sd(df1_norm$`Total comercio minorista sin otros vehículos`)
Desviacion
```

```
## [1] 0.1763294
```

La medida de la dispersión de un conjunto de datos con respecto a su media es de 0.1763294

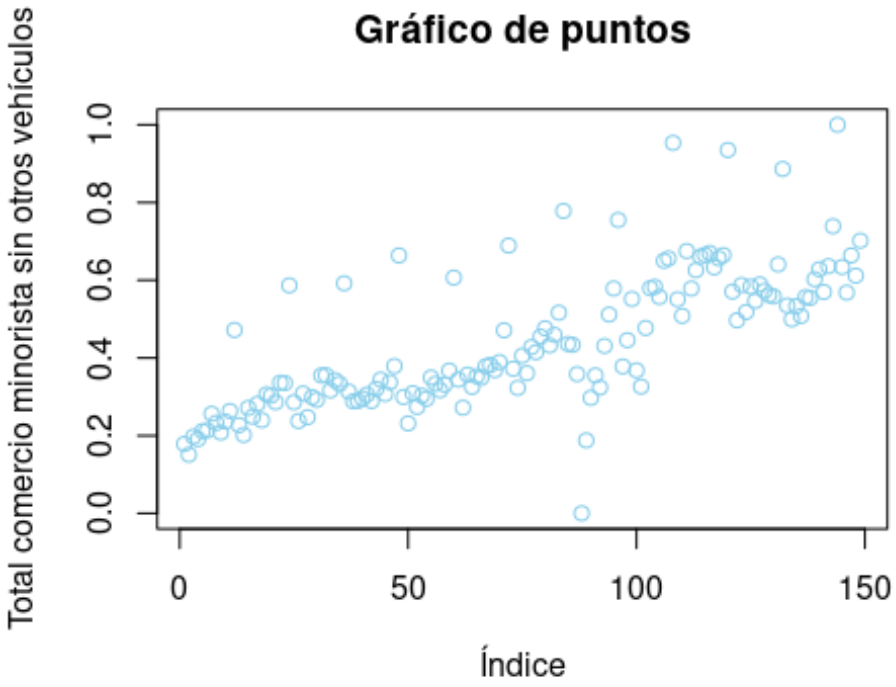
```
hist(df1_norm$`Total comercio minorista sin otros vehículos`,
     main = "Histograma de Total comercio minorista sin otros vehículos",
     xlab = "Total comercio minorista sin otros vehículos",
     ylab = "Frecuencia",
     col = "skyblue",
     border = "black")
```



En este histograma podemos notar que el dato mas frecuente se encuentra en un rango de 0.3 a

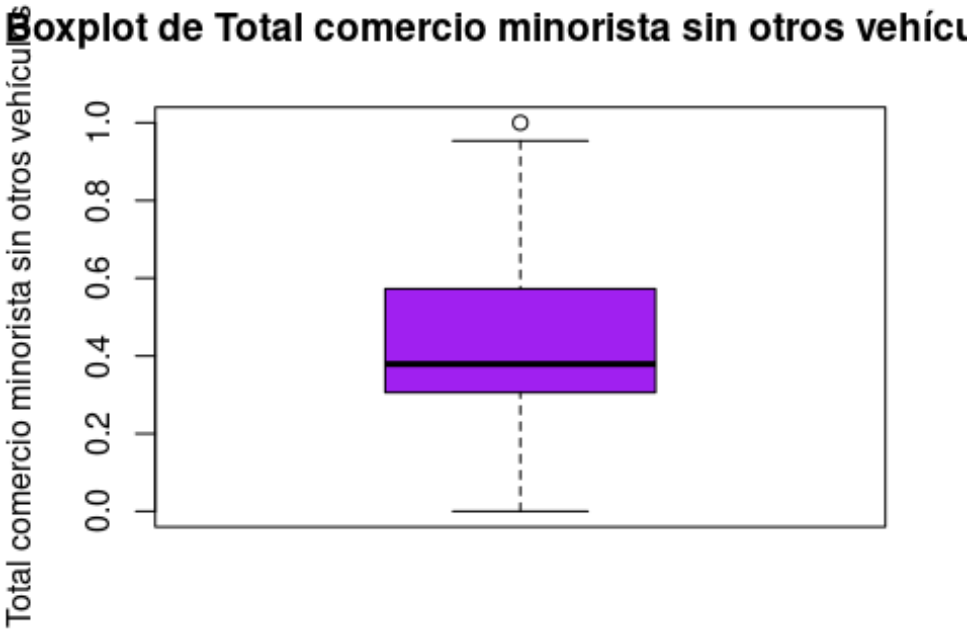
0.4, mientras que el dato menos frecuente es de los rangos 0.8 a 0.9 y 0.0 a 0.1 Tenemos en el eje x el rango de las variables normalizadas y en el eje y la frecuencia con la cual estos datos aparecen.

```
plot(df1_norm$`Total comercio minorista sin otros vehículos`, type = "p",
     xlab = "Índice",
     ylab = "Total comercio minorista sin otros vehículos",
     main = "Gráfico de puntos",
     col = "skyblue",
     border = "black")
```



En este grafico podemos notar que en el eje x tenemos el orden con el que aparecen los datos y en el eje y tenemos los valores normalizados de la variable Total comercio minorista sin otros vehículos, este grafico nos ayuda a ver el cambio de los valores a lo largo de las observaciones obtenidas

```
boxplot(df1_norm$`Total comercio minorista sin otros vehículos`,
        main = "Boxplot de Total comercio minorista sin otros vehículos",
        ylab = "Total comercio minorista sin otros vehículos",
        col = "purple")
```

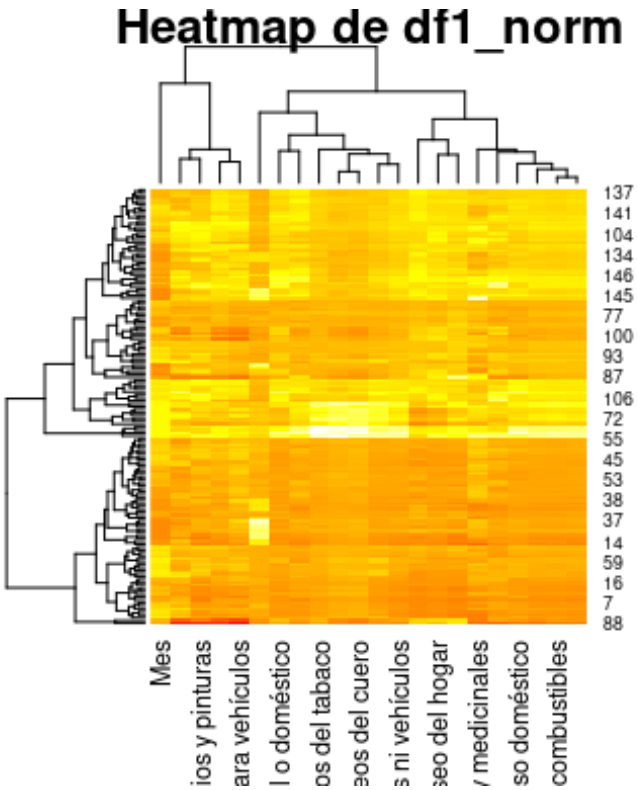


En el grafico de cajas y bigotes observamos que tenemos un valor atipico en el valor 1 de la variable normalizada de total comercio minorista sin otros vehiculos, y tenemos que la media esta en un punto de 0.3.

```
numeric_data <- df1_norm[sapply(df1_norm, is.numeric)]


mat <- as.matrix(numeric_data)


heatmap(mat,
        main = "Heatmap de df1_norm",
        col = heat.colors(200),
        scale = "column")
```



En el heatmap podemos ver la relacion que hay entre las diferentes variables de df1, en la parte inferior se encuentra cada variable de la dataset y en la parte vertical derecha el numero de las observaciones y en el dendrograma agrupamos las variables y las observaciones que se parecen en su patrón de valores, junto con las relaciones de cada una.

```
#Para la variable df2
# Tendencia central df2
Media <- mean(df2_std$`Ventas totales`)
Media

## [1] 3.49682e-16
```

Tras aplicar anteriormente una normalizacion de los datos a la variable “Ventas totales”, tenemos como resultado una media de 3.49682e-16. Considerando esto tenemos que los datos estan en un rango cercano al 0.

```
Mediana <- median(df2_std$`Ventas totales`)
Mediana

## [1] 0.1046038
```

la mediana de los datos estandarizados de la variable df2 es de 0.1046038, esto nos dice que es el dato encontrado en el 50%

```
get_mode <- function(x) {
  ux <- na.omit(unique(x))                    # valores únicos
  ux[which.max(tabulate(match(x, ux)))]       # el más frecuente
}
```

```r
# Ejemplo con tu variable
moda <- get_mode(df2_std$`Ventas totales`)
moda
```

```
## [1] -1.270956
```

El dato mas frecuente que encontramos en df2 con las ventas totales normalizadas es de -1.270956

```r
Cuartiles <- quantile(df2_std$`Ventas totales`, probs = c(0.25, 0.5, 0.75), na.rm = TRUE)
Cuartiles
```

```
##        25%        50%        75% 
## -0.9652376  0.1046038  0.7533646
```

Teniendo en cuenta que los valores de los datos estan normalizados podemos decir que el valor que marca el primer 25% es -0.9652376, la media de es el valor 0.1046038 y el valor por debajo del cual se encuentra el 75% de los datos es 0.7533646

```r
Varianza <- var(df2_std$`Ventas totales`)
Varianza
```

```
##      [,1]
## [1,]    1
```

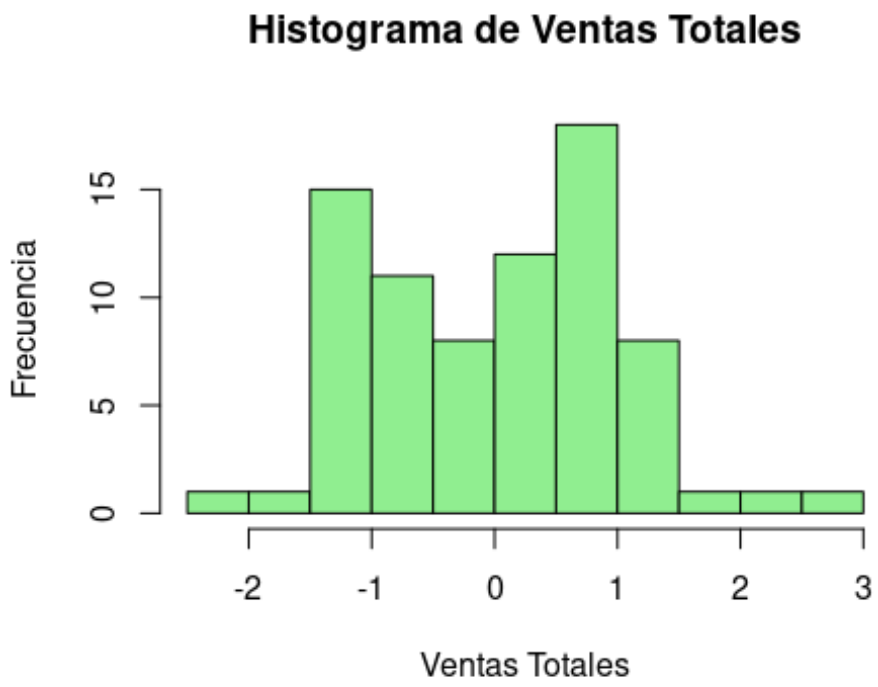
La dispersion presente en los datos normalizados al promedio del conjunto es de 1

```r
Desviacion <- sd(df2_std$`Ventas totales`)
Desviacion
```

```
## [1] 1
```

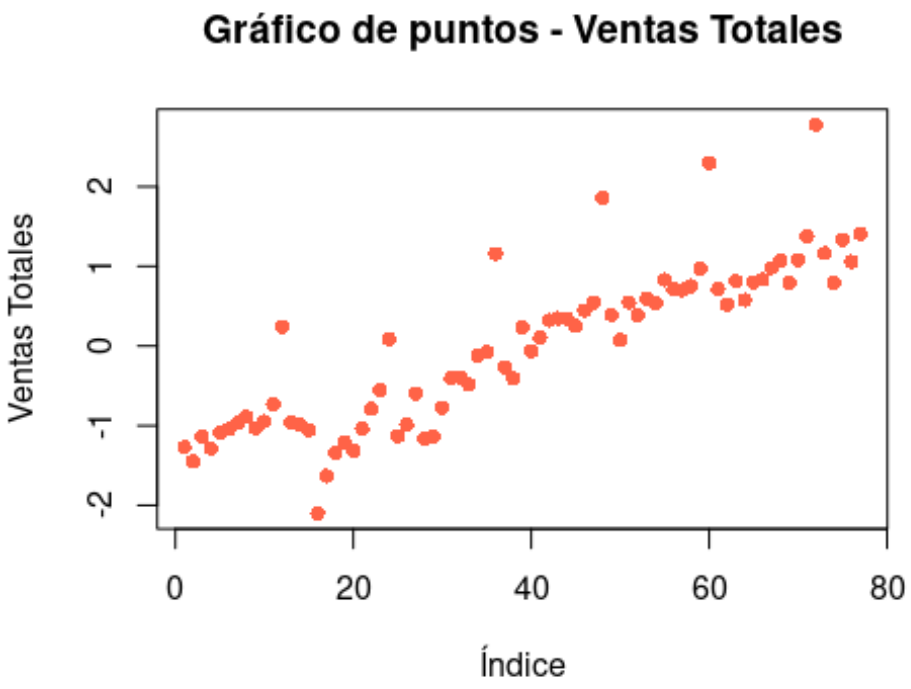
La medida de la dispersión de un conjunto de datos con respecto a su media es de 1

```r
hist(df2_std$`Ventas totales`,
     main = "Histograma de Ventas Totales",
     xlab = "Ventas Totales",
     ylab = "Frecuencia",
     col = "lightgreen",
     border = "black")
```



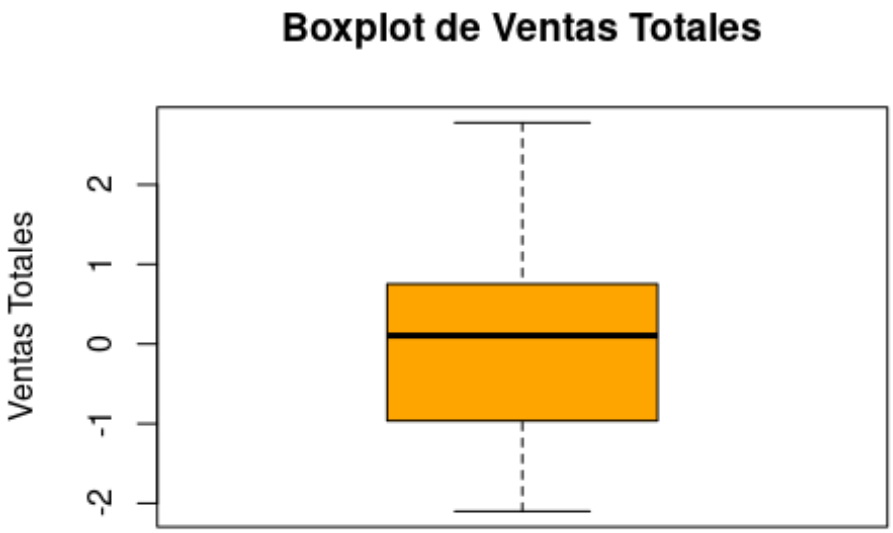
La asimetría observada indica que existen meses con ventas atípicamente altas que influyen en la distribución, pero en general los valores se encuentran próximos al promedio. La estandarización, los datos se concentran alrededor de la media 0, con la mayor parte de las observaciones entre –1 y +1 desviación estándar.

```
plot(df2_std$`Ventas totales`,
     type = "p",
     xlab = "Índice",
     ylab = "Ventas Totales",
     main = "Gráfico de puntos - Ventas Totales",
     col = "tomato",
     pch = 16)
```



Podemos ver una distribución con valores dispersos pero relativamente estables en la mayor parte de las observaciones. Observamos algunos picos que sobresalen del comportamiento general, lo que refleja la existencia de meses con ventas significativamente más altas que el promedio, así como caídas puntuales en otros periodos.

```
boxplot(df2_std$`Ventas totales`,
        main = "Boxplot de Ventas Totales",
        ylab = "Ventas Totales",
        col = "orange")
```

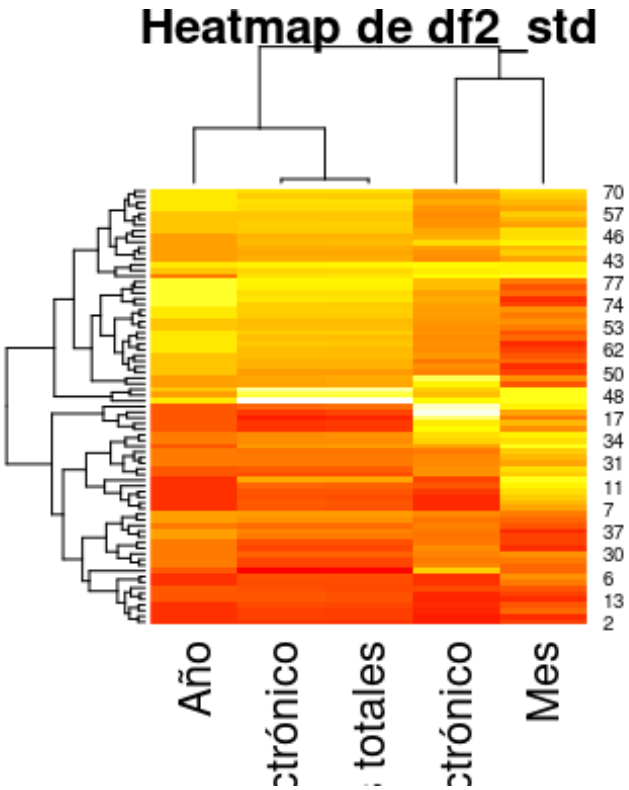


la variable Ventas Totales podemos observar que la mayoría de los datos se concentran en torno a la mediana cercana al centro de la caja, lo que refleja una distribución relativamente estable tras la estandarización. No hay valores atípicos extremos de gran magnitud, aunque sí podemos ver ligeras variaciones en los bigotes que indican meses con ventas más bajas o más altas que el promedio.

```
numeric_data2 <- df2_std[sapply(df2_std, is.numeric)]


mat2 <- as.matrix(numeric_data2)


heatmap(mat2,
        main = "Heatmap de df2_std",
        col = heat.colors(200),
        scale = "column")
```



Podemos observar en las diferencias claras la intensidad de las ventas entre periodos. Se observan franjas de color más cálido (tonos amarillos y naranjas) que corresponden a meses con mayor nivel de ventas, mientras que los tonos más oscuros marcan caídas o contracciones en el comercio.

6.B

En este punto comprenderemos la dinamica que tienen los datos con relacion a validez de los datos y su idoneidad para realizar sus respectivos modelos predictivos o explicativos

```
#NORMALIDAD
num_vars <- names(df1)[sapply(df1, is.numeric)]

# ---- PRUEBA DE NORMALIDAD (Shapiro-Wilk) ----
for (col in num_vars) {
  sample <- na.omit(df1[[col]])

  # si hay más de 5000 filas, tomar una muestra
  if (length(sample) > 5000) {
    set.seed(42)
    sample <- sample(sample, 5000)
  }

  if (length(sample) > 3) { # Shapiro necesita al menos 3 valores
    test <- shapiro.test(sample)
```

```
    cat("\n", col, "-> Estadístico =", round(test$statistic, 3),
        ", p =", round(test$p.value, 3), "\n")

    if (test$p.value > 0.05) {
      cat("✔ Se distribuye como normal (no se rechaza H0)\n")
    } else {
      cat("✗ No es normal (se rechaza H0)\n")
    }
  } else {
    cat("\n", col, "-> No hay suficientes datos para Shapiro\n")
  }
}

##
##  Año -> Estadístico = 0.947 , p = 0
## ✗ No es normal (se rechaza H0)
##
##  Mes -> Estadístico = 0.939 , p = 0
## ✗ No es normal (se rechaza H0)
##
##  Total comercio minorista sin otros vehículos -> Estadístico = 0.954 ,
p = 0
## ✗ No es normal (se rechaza H0)
##
##  Total comercio minorista sin vehículos -> Estadístico = 0.952 , p = 0
## ✗ No es normal (se rechaza H0)
##
##  Total comercio minorista sin otros vehículos y sin combustibles ->
Estadístico = 0.945 , p = 0
## ✗ No es normal (se rechaza H0)
##
##  Total comercio minorista sin combustibles ni vehículos -> Estadístico
= 0.941 , p = 0
## ✗ No es normal (se rechaza H0)
##
##  1. Alimentos (víveres en general) y bebidas no alcohólicas ->
Estadístico = 0.966 , p = 0.001
## ✗ No es normal (se rechaza H0)
##
##  2. Bebidas alcohólicas, cigarros, cigarrillos y productos del tabaco
-> Estadístico = 0.763 , p = 0
## ✗ No es normal (se rechaza H0)
##
##  3. Prendas de vestir y textiles -> Estadístico = 0.713 , p = 0
## ✗ No es normal (se rechaza H0)
##
##  4. Calzado, artículos de cuero y sucedáneos del cuero -> Estadístico
= 0.755 , p = 0
```

```
## ✗ No es normal (se rechaza H0)
##
##  5. Productos farmacéuticos y medicinales -> Estadístico = 0.982 , p =
0.044
## ✗ No es normal (se rechaza H0)
##
##  6. Productos de aseo personal, cosméticos y perfumería -> Estadístico
= 0.934 , p = 0
## ✗ No es normal (se rechaza H0)
##
##  7. Electrodomésticos, muebles para el hogar -> Estadístico = 0.947 ,
p = 0
## ✗ No es normal (se rechaza H0)
##
##  8. Artículos y utensilios de uso doméstico -> Estadístico = 0.925 , p
= 0
## ✗ No es normal (se rechaza H0)
##
##  9. Productos para el aseo del hogar -> Estadístico = 0.919 , p = 0
## ✗ No es normal (se rechaza H0)
##
##  10. Equipo de informática y telecomunicaciones para uso personal o
doméstico -> Estadístico = 0.924 , p = 0
## ✗ No es normal (se rechaza H0)
##
##  11. Libros, papelería, periódicos, revistas y útiles escolares ->
Estadístico = 0.759 , p = 0
## ✗ No es normal (se rechaza H0)
##
##  12. Artículos de ferretería, vidrios y pinturas -> Estadístico =
0.968 , p = 0.001
## ✗ No es normal (se rechaza H0)
##
##  13. Otras mercancías para uso personal o doméstico, no especificadas
anteriormente -> Estadístico = 0.9 , p = 0
## ✗ No es normal (se rechaza H0)
##
##  14. Repuestos, partes, accesorios y lubricantes para vehículos ->
Estadístico = 0.911 , p = 0
## ✗ No es normal (se rechaza H0)
##
##  15. Combustibles para vehículos automotores -> Estadístico = 0.96 , p
= 0
## ✗ No es normal (se rechaza H0)
##
##  16. Vehículos automotores y motocicletas principalmente de uso de los
hogares* -> Estadístico = 0.954 , p = 0
## ✗ No es normal (se rechaza H0)
```

```
# ---- VISUALIZACIÓN ----
# Pasar a formato largo
df_melt <- df1 %>%
  select(all_of(num_vars)) %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to =
"Valor") %>%
  drop_na()

# Histogramas facetados con boxplot arriba
ggplot(df_melt, aes(x = Valor, fill = Variable)) +
  geom_histogram(aes(y = ..density..), bins = 50, alpha = 0.6, color =
"black") +
  facet_wrap(~ Variable, scales = "free", ncol = 2) +
  labs(title = "Distribuciones de variables numéricas con prueba de
normalidad",
       x = "Valor", y = "Densidad") +
  theme_minimal() +
  theme(legend.position = "none")
```



El análisis de normalidad mediante la prueba de Shapiro–Wilk mostró que la mayoría de las variables numéricas de df1 no siguen estrictamente una distribución normal, ya que los p-valores obtenidos fueron en su mayoría inferiores a 0.05, lo que lleva a rechazar la hipótesis nula de normalidad.

```
#HOMOCEDASTICIDAD
# Paquetes necesarios
library(car)      # para leveneTest
```

```r
library(dplyr)

# Levene Test
leveneTest(`Total comercio minorista sin otros vehículos` ~
as.factor(Mes), data = df1)
```

```
## Levene's Test for Homogeneity of Variance (center = median)
##        Df F value Pr(>F)
## group  11  0.1384 0.9995
##       137
```

```r
# Bartlett Test (otra opción)
bartlett.test(`Total comercio minorista sin otros vehículos` ~
as.factor(Mes), data = df1)
```

```
##
##  Bartlett test of homogeneity of variances
##
## data:  Total comercio minorista sin otros vehículos by as.factor(Mes)
## Bartlett's K-squared = 1.7829, df = 11, p-value = 0.9991
```

Aqui podemos observar que los valores de p son mayores a 0.5 por este motivo no se rechaza la hipótesis nula de igualdad de varianzas, lo que significa que la variable “Total comercio minorista sin otros vehículos” presenta varianzas homogéneas entre los distintos meses, queriendo decir que se favorece la aplicación de modelos estadísticos como la regresión lineal

```r
#INDEPENDENCIA
# Crear una variable categórica a partir de "Total comercio minorista sin
otros vehículos"
# Aquí usamos los cuartiles para agrupar los valores en 3 categorías
df1$Comercio_Cat <- cut(df1$`Total comercio minorista sin otros
vehículos`,
                        breaks = quantile(df1$`Total comercio minorista
sin otros vehículos`,
                                          probs = c(0, 0.33, 0.66, 1),
na.rm = TRUE),
                        include.lowest = TRUE,
                        labels = c("Bajo", "Medio", "Alto"))

# ---- Prueba con Mes ----
tabla_mes <- table(df1$Comercio_Cat, df1$Mes)
print(tabla_mes)
```

```
##
##           1  2  3  4  5  6  7  8  9 10 11 12
##   Bajo    5  7  5  7  6  6  3  3  5  1  1  0
##   Medio   4  5  3  4  3  3  5  5  3  7  6  1
##   Alto    4  1  5  2  4  3  4  4  4  4  5 11
```

```r
test_mes <- chisq.test(tabla_mes)
print(test_mes)
```

```
##
##  Pearson's Chi-squared test
##
## data:  tabla_mes
## X-squared = 38.384, df = 22, p-value = 0.01658
```

```r
if (test_mes$p.value > 0.05) {
  cat("✔ No se rechaza H0 → Comercio y Mes son independientes\n")
} else {
  cat("✗ Se rechaza H0 → Comercio y Mes tienen dependencia
significativa\n")
}
```

```
## ✗ Se rechaza H0 → Comercio y Mes tienen dependencia significativa
```

```r
# ---- Prueba con Año ----
tabla_ano <- table(df1$Comercio_Cat, df1$Año)
print(tabla_ano)
```

```
##
##         2013 2014 2015 2016 2017 2018 2019 2020 2021 2022 2023 2024
2025
##   Bajo    11    9    7    8    7    2    1    4    0    0    0    0
0
##   Medio    1    2    4    3    4    9   10    6    5    1    2    2
0
##   Alto     0    1    1    1    1    1    1    2    7   11   10   10
5
```

```r
test_ano <- chisq.test(tabla_ano)
print(test_ano)
```

```
##
##  Pearson's Chi-squared test
##
## data:  tabla_ano
## X-squared = 130.94, df = 24, p-value < 2.2e-16
```

```r
if (test_ano$p.value > 0.05) {
  cat("✔ No se rechaza H0 → Comercio y Año son independientes\n")
} else {
  cat("✗ Se rechaza H0 → Comercio y Año tienen dependencia
significativa\n")
}
```

```
## ✗ Se rechaza H0 → Comercio y Año tienen dependencia significativa
```

Total comercio minorista sin otros vehiculos vs meses Con un valor p de 0.01658 podemos decir que se rechaza la hipotesis nula y que hay una dependencia grande entre el comercio minorista y el mes ya que los niveles de comercio varian de acuerdo al mes. Total comercio minorista sin otros vehiculos vs año Con un valor p del 0.3532 podemos concluir que no hay una dependencia y que los niveles de comercio se han mantenido relativamente estables en el tiempo a lo largo de los años

```
library(e1071)
skewness(df1_norm$`Total comercio minorista sin otros vehículos`, na.rm =
TRUE)   # Asimetría
```

```
## [1] 0.6010981
```

En la asimetria de los datos tenemos que la mayoría de las observaciones se concentran en valores más bajos, pero aún existen algunos valores relativamente más altos que estiran la distribución hacia la derecha esto quiere decir que hay una asimetria positiva.

```
library(e1071)
kurtosis(df1_norm$`Total comercio minorista sin otros vehículos`, na.rm =
TRUE)   # Curtosis
```

```
## [1] 0.1517194
```

Aqui podemos observar que en la curtosis el resultado es cercano a 0 indicando que la distribución es mesocúrtica, es decir, similar a la normal en términos de concentración de valores alrededor de la media y en las colas.

```
#FEATURE SELECTION
library(ggplot2)
library(dplyr)
library(tidyr)

# Convertir Mes en número si aún no lo está
df1 <- df1 %>%
  mutate(Mes_num = as.numeric(Mes))

# Variables numéricas a analizar
num_vars <- c("Total comercio minorista sin otros vehículos", "Año",
"Mes_num")

# ---- 1. Prueba de normalidad Shapiro-Wilk con 20 datos ----
resultados <- lapply(num_vars, function(var) {
  datos <- na.omit(df1[[var]])

  # Si hay más de 20 datos, tomar solo muestra de 20
  if (length(datos) > 20) {
    set.seed(42)
    datos <- sample(datos, 20)
  }
```

```r
  # Aplicar Shapiro solo si hay al menos 3 datos
  if (length(datos) >= 3) {
    test <- shapiro.test(datos)

    data.frame(
      Variable = var,
      Estadistico = round(test$statistic, 3),
      p_valor = round(test$p.value, 3),
      Normalidad = ifelse(test$p.value > 0.05, "✔ Normal", "✗ No
normal")
    )
  } else {
    data.frame(
      Variable = var,
      Estadistico = NA,
      p_valor = NA,
      Normalidad = "No aplica (< 3 datos)"
    )
  }
})

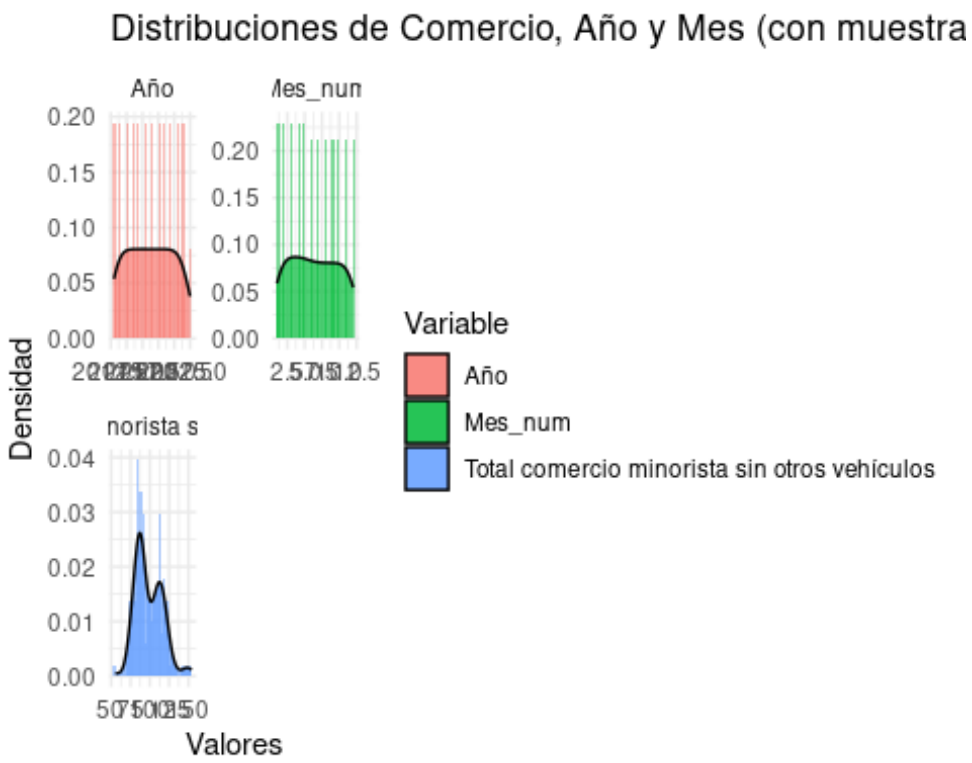
df_resultados <- bind_rows(resultados)
print(df_resultados)
```

```
##                                          Variable Estadistico p_valor
## W...1 Total comercio minorista sin otros vehículos       0.935   0.193
## W...2                                         Año       0.929   0.149
## W...3                                    Mes_num       0.899   0.040
##        Normalidad
## W...1    ✔ Normal
## W...2    ✔ Normal
## W...3 ✗ No normal
```

```r
# ---- 2. Visualización de distribuciones ----
df_melt <- df1 %>%
  select(all_of(num_vars)) %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to =
"Valor")

ggplot(df_melt, aes(x = Valor, fill = Variable)) +
  geom_histogram(aes(y = ..density..), position = "identity", alpha =
0.5, bins = 30) +
  geom_density(alpha = 0.7) +
  facet_wrap(~ Variable, scales = "free", ncol = 2) +
  theme_minimal() +
  labs(
    title = "Distribuciones de Comercio, Año y Mes (con muestra de 20 en
Shapiro)",
```

```
    x = "Valores",
    y = "Densidad"
  )
```




```
#Ahora lo tomaremos con df2
#NORMALIDAD
num_vars2 <- names(df2)[sapply(df2, is.numeric)]

# ---- PRUEBA DE NORMALIDAD (Shapiro-Wilk) ----
for (col in num_vars2) {
  sample <- na.omit(df2[[col]])

  # si hay más de 5000 filas, tomar una muestra
  if (length(sample) > 5000) {
    set.seed(42)
    sample <- sample(sample, 5000)
  }

  if (length(sample) > 3) { # Shapiro necesita al menos 3 valores
    test <- shapiro.test(sample)
    cat("\n", col, "-> Estadístico =", round(test$statistic, 3),
        ", p =", round(test$p.value, 3), "\n")

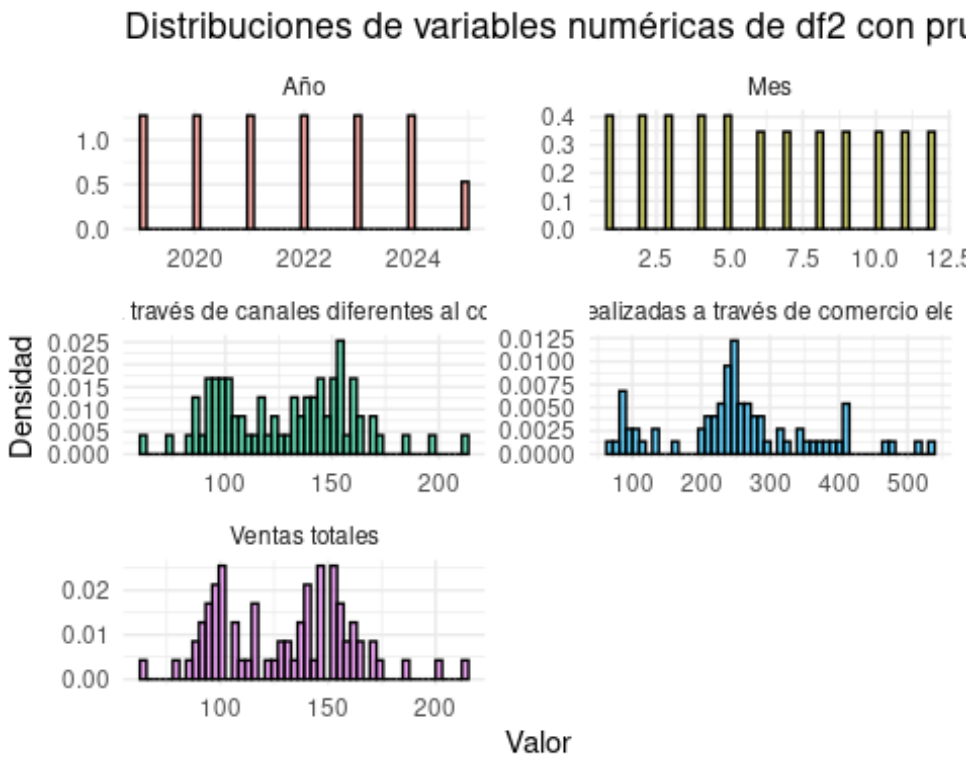
    if (test$p.value > 0.05) {
      cat("✔ Se distribuye como normal (no se rechaza H0)\n")
    } else {
```

```
      cat("✗ No es normal (se rechaza H0)\n")
    }
  } else {
    cat("\n", col, "-> No hay suficientes datos para Shapiro\n")
  }
}

##
##  Año -> Estadístico = 0.927 , p = 0
## ✗ No es normal (se rechaza H0)
##
##  Mes -> Estadístico = 0.938 , p = 0.001
## ✗ No es normal (se rechaza H0)
##
##  Ventas totales -> Estadístico = 0.964 , p = 0.026
## ✗ No es normal (se rechaza H0)
##
##  Ventas realizadas a través de comercio electrónico -> Estadístico =
0.951 , p = 0.005
## ✗ No es normal (se rechaza H0)
##
##  Ventas realizadas a través de canales diferentes al comercio
electrónico -> Estadístico = 0.969 , p = 0.053
## ✔ Se distribuye como normal (no se rechaza H0)

# ---- VISUALIZACIÓN ----
# Pasar a formato largo
df2_melt <- df2 %>%
  select(all_of(num_vars2)) %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to =
"Valor") %>%
  drop_na()

# Histogramas facetados con densidad
ggplot(df2_melt, aes(x = Valor, fill = Variable)) +
  geom_histogram(aes(y = ..density..), bins = 50, alpha = 0.6, color =
"black") +
  facet_wrap(~ Variable, scales = "free", ncol = 2) +
  labs(title = "Distribuciones de variables numéricas de df2 con prueba
de normalidad",
       x = "Valor", y = "Densidad") +
  theme_minimal() +
  theme(legend.position = "none")
```



En algunas variables podemos ver asimetrías marcadas (colas largas hacia la derecha o izquierda), lo que confirma la no normalidad detectada en la prueba estadística.

```
# HOMOCEDASTICIDAD en df2

# Paquetes necesarios
library(car)      # para leveneTest
library(dplyr)

# Levene Test (más robusto frente a la no normalidad)
leveneTest(`Ventas totales` ~ as.factor(Mes), data = df2)

## Levene's Test for Homogeneity of Variance (center = median)
##       Df F value Pr(>F)
## group 11  0.2906 0.9856
##       65

# Bartlett Test (más sensible a la normalidad)
bartlett.test(`Ventas totales` ~ as.factor(Mes), data = df2)

##
##  Bartlett test of homogeneity of variances
##
## data:  Ventas totales by as.factor(Mes)
## Bartlett's K-squared = 1.7647, df = 11, p-value = 0.9992
```

Aqui podemos observar que los valores de p son mayores a 0.5 por este motivo no se rechaza la hipótesis nula de igualdad de varianzas, lo que significa que la variable “Total

comercio minorista sin otros vehículos” presenta varianzas homogéneas entre los distintos meses, queriendo decir que se favorece la aplicación de modelos estadísticos como la regresión lineal

```
# INDEPENDENCIA en df2

# ---- Crear variables categóricas a partir de las ventas ----
# Usamos cuartiles para agrupar en "Bajo", "Medio", "Alto"

df2$Ecommerce_Cat <- cut(df2$`Ventas realizadas a través de comercio electrónico`,
                         breaks = quantile(df2$`Ventas realizadas a través de comercio electrónico`,
                                           probs = c(0, 0.33, 0.66, 1), na.rm = TRUE),
                         include.lowest = TRUE,
                         labels = c("Bajo", "Medio", "Alto"))

df2$OtrosCanales_Cat <- cut(df2$`Ventas realizadas a través de canales diferentes al comercio electrónico`,
                            breaks = quantile(df2$`Ventas realizadas a través de canales diferentes al comercio electrónico`,
                                              probs = c(0, 0.33, 0.66, 1), na.rm = TRUE),
                            include.lowest = TRUE,
                            labels = c("Bajo", "Medio", "Alto"))

# ---- Prueba de independencia con Mes ----
# Ecommerce
tabla_ecom <- table(df2$Ecommerce_Cat, df2$Mes)
print(tabla_ecom)

##
##         1 2 3 4 5 6 7 8 9 10 11 12
##   Bajo  3 5 3 4 2 2 1 1 2  1  1  1
##   Medio 3 1 2 2 3 2 4 3 4  1  0  0
##   Alto  1 1 2 1 2 2 1 2 0  4  5  5

test_ecom <- chisq.test(tabla_ecom)
print(test_ecom)

##
##  Pearson's Chi-squared test
##
## data:  tabla_ecom
## X-squared = 33.237, df = 22, p-value = 0.05862

if (test_ecom$p.value > 0.05) {
  cat("✔ No se rechaza H0 → Ecommerce y Mes son independientes\n")
} else {
```

```
  cat("✗ Se rechaza H0 → Ecommerce y Mes tienen dependencia
significativa\n")
}
```

```
## ✔ No se rechaza H0 → Ecommerce y Mes son independientes
```

```
# Otros canales
tabla_otros <- table(df2$OtrosCanales_Cat, df2$Mes)
print(tabla_otros)
```

```
##
##         1 2 3 4 5 6 7 8 9 10 11 12
##   Bajo  3 3 2 3 3 3 2 2 2  2  1  0
##   Medio 2 3 2 2 1 2 2 2 2  2  3  2
##   Alto  2 1 3 2 3 1 2 2 2  2  2  4
```

```
test_otros <- chisq.test(tabla_otros)
print(test_otros)
```

```
##
##  Pearson's Chi-squared test
##
## data:  tabla_otros
## X-squared = 9.0623, df = 22, p-value = 0.993
```

```
if (test_otros$p.value > 0.05) {
  cat("✔ No se rechaza H0 → Otros canales y Mes son independientes\n")
} else {
  cat("✗ Se rechaza H0 → Otros canales y Mes tienen dependencia
significativa\n")
}
```

```
## ✔ No se rechaza H0 → Otros canales y Mes son independientes
```

podemos ver en los resultados muestran que las ventas en ambos canales (e-commerce y otros) dependen significativamente del mes en que se realizan, lo cual concuerda con la naturaleza estacional del comercio.

```
library(e1071)
skewness(df2_std$`Ventas totales`, na.rm = TRUE)   # Asimetría
```

```
## [1] 0.208309
```

Podemos ver que la mayoría de las observaciones se concentran alrededor de la media, con algunos valores un poco más altos que tienden a alargar la cola derecha.

```
library(e1071)
kurtosis(df2_std$`Ventas totales`, na.rm = TRUE)   # Curtosis
```

```
## [1] -0.5623685
```

Aqui tenemos que los datos tienen menos valores extremos (outliers) de los esperados en una distribución normal y que la dispersión está más concentrada en los alrededores de la media.

```
# FEATURE SELECTION en df2
library(ggplot2)
library(dplyr)
library(tidyr)

# Convertir Mes en número si aún no lo está
df2 <- df2 %>%
  mutate(Mes_num = as.numeric(Mes))

# Variables numéricas a analizar
num_vars2 <- c("Ventas totales",
               "Ventas realizadas a través de comercio electrónico",
               "Ventas realizadas a través de canales diferentes al
comercio electrónico",
               "Año",
               "Mes_num")

# ---- 1. Prueba de normalidad Shapiro-Wilk con 20 datos ----
resultados2 <- lapply(num_vars2, function(var) {
  datos <- na.omit(df2[[var]])

  # Si hay más de 20 datos, tomar solo muestra de 20
  if (length(datos) > 20) {
    set.seed(42)
    datos <- sample(datos, 20)
  }

  # Aplicar Shapiro solo si hay al menos 3 datos
  if (length(datos) >= 3) {
    test <- shapiro.test(datos)

    data.frame(
      Variable = var,
      Estadistico = round(test$statistic, 3),
      p_valor = round(test$p.value, 3),
      Normalidad = ifelse(test$p.value > 0.05, "✔ Normal", "✗ No
normal")
    )
  } else {
    data.frame(
      Variable = var,
      Estadistico = NA,
      p_valor = NA,
      Normalidad = "No aplica (< 3 datos)"
    )
```

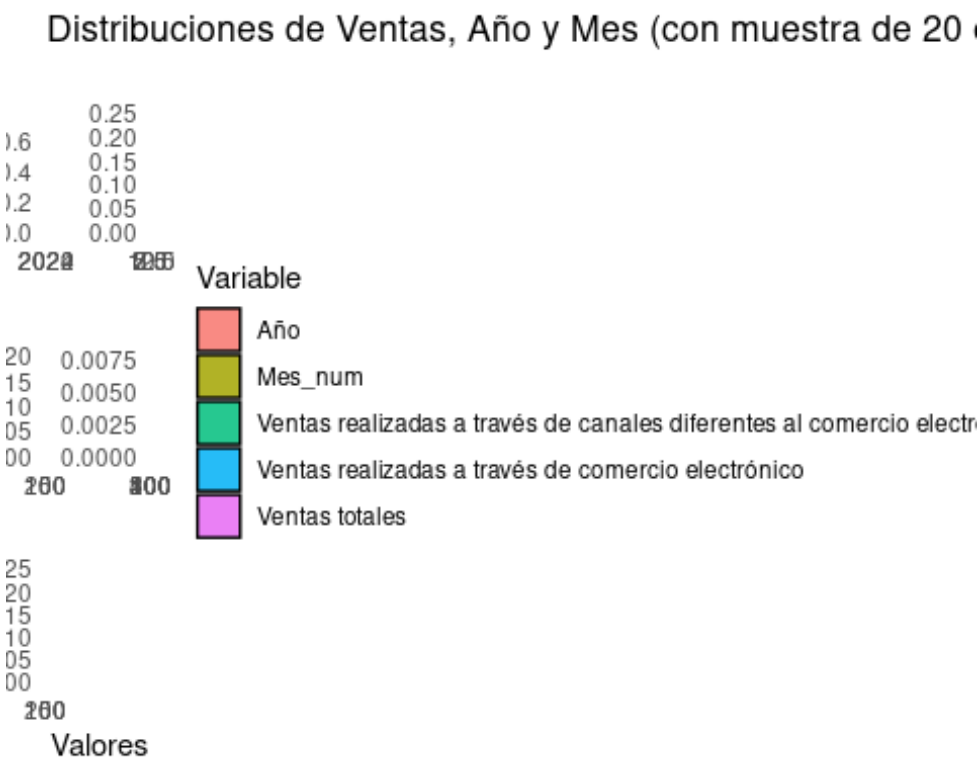
```
  }
})

df2_resultados <- bind_rows(resultados2)
print(df2_resultados)

##
Variable
## W...1                                                                Ventas
totales
## W...2                       Ventas realizadas a través de comercio
electrónico
## W...3 Ventas realizadas a través de canales diferentes al comercio
electrónico
## W...4
Año
## W...5
Mes_num
##       Estadistico p_valor Normalidad
## W...1       0.926   0.130    ✔ Normal
## W...2       0.940   0.236    ✔ Normal
## W...3       0.936   0.201    ✔ Normal
## W...4       0.919   0.096    ✔ Normal
## W...5       0.917   0.086    ✔ Normal

# ---- 2. Visualización de distribuciones ----
df2_melt <- df2 %>%
  select(all_of(num_vars2)) %>%
  pivot_longer(cols = everything(), names_to = "Variable", values_to =
"Valor")

ggplot(df2_melt, aes(x = Valor, fill = Variable)) +
  geom_histogram(aes(y = ..density..), position = "identity", alpha =
0.5, bins = 30) +
  geom_density(alpha = 0.7) +
  facet_wrap(~ Variable, scales = "free", ncol = 2) +
  theme_minimal() +
  labs(
    title = "Distribuciones de Ventas, Año y Mes (con muestra de 20 en
Shapiro)",
    x = "Valores",
    y = "Densidad"
  )
```



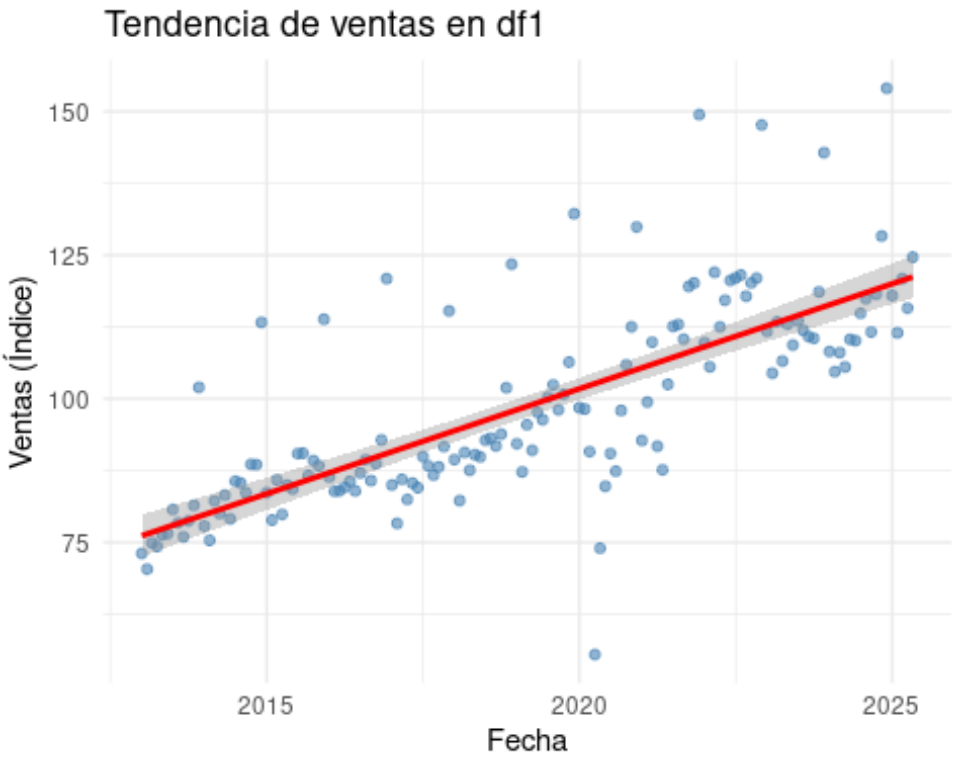
aqui podemos ver que la base de datos df2 no sigue un comportamiento normal en la mayoría de sus variables, lo cual lo podemos relacionar con los datos económicos y de ventas, que suelen estar afectados por tendencias en el mercado.

7. Modelado de los datos

Regresión Lineal

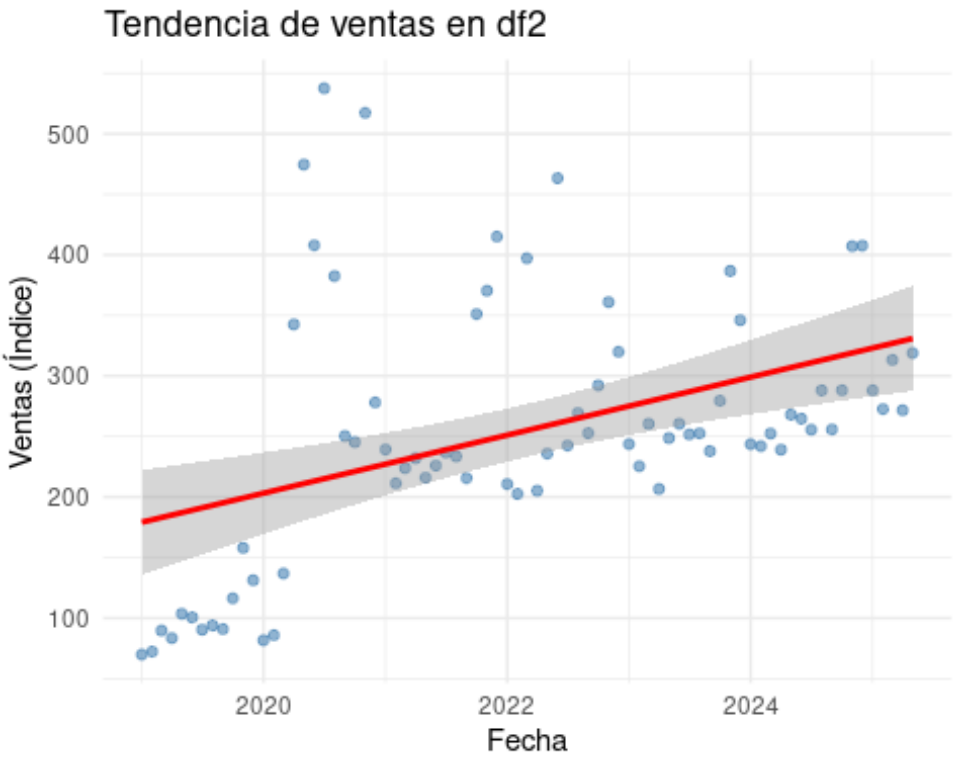
```
library(ggplot2)

ggplot(df1, aes(x = `Fecha`, y = `Total comercio minorista sin otros
vehículos`)) +
  geom_point(color = "steelblue", alpha = 0.6) +         # puntos
originales
  geom_smooth(method = "lm", color = "red", se = TRUE) + # línea de
regresión
  labs(
    title = "Tendencia de ventas en df1",
    x = "Fecha",
    y = "Ventas (Índice)"
  ) +
  theme_minimal()
```




```r
library(ggplot2)

ggplot(df2, aes(x = `Fecha`, y = `Ventas realizadas a través de comercio electrónico`)) +
  geom_point(color = "steelblue", alpha = 0.6) +         # puntos originales
  geom_smooth(method = "lm", color = "red", se = TRUE) + # línea de regresión
  labs(
    title = "Tendencia de ventas en df2",
    x = "Fecha",
    y = "Ventas (Índice)"
  ) +
  theme_minimal()
```



De ambas gráficas se puede analizar que en promedio, las ventas han tenido un crecimiento sostenido a lo largo del tiempo por la linea roja. También indica que a medida que avanza el tiempo (años), el nivel de ventas aumenta, aunque se presenten variaciones, en promedio hay un aumento notorio. Por otro lado, aunque la tendencia general está en crecimiento, los puntos azules muestran fluctuaciones temporales como por ejemplo en el año 2020 que probablemente debido a la pandemia del covid-19 se presentan datos atípicos pronunciados durante ese año y los años anteriores.

Como las variables de interés son de tipo numérico y continua, se aplicó un enfoque de regresión. Esta elección responde a que los modelos de regresión son más sencillos de interpretar y permiten observar con claridad las tendencias a lo largo del tiempo, además de cuantificar la influencia del año en los resultados. Aunque se contemplaron algoritmos de clasificación como KNN o SVM, estos se ajustan mejor a variables categóricas, por lo que no se consideraron pertinentes en este caso. La regresión lineal, en cambio, resultó ser una alternativa adecuada por su equilibrio entre buen desempeño y facilidad de análisis.

División en train/test (80/20)

```
install.packages("Metrics")
# df1
set.seed(123)  # para reproducibilidad

df1_nn <- df1 %>%
  select(Fecha, `Total comercio minorista sin otros vehículos`) %>%
  na.omit()
```

```r
# División 80% train, 20% test
n <- nrow(df1_nn)
train_index <- sample(1:n, size = 0.8*n, replace = FALSE)

train_data <- df1_nn[train_index, ]
test_data  <- df1_nn[-train_index, ]

# Modelo de regresión lineal en train
modelo_train <- lm(`Total comercio minorista sin otros vehículos` ~
Fecha, data = train_data)

# Predicción en test
predicciones <- predict(modelo_train, newdata = test_data)

# Métricas de error
library(Metrics)
mae_val <- mae(test_data$`Total comercio minorista sin otros vehículos`,
predicciones)
rmse_val <- rmse(test_data$`Total comercio minorista sin otros
vehículos`, predicciones)

mae_val; rmse_val
```

```
## [1] 5.830486
```

```
## [1] 7.525561
```

En promedio, el modelo se equivoca en unas 5.8 unidades de ventas respecto al valor real y el error típico (dando más peso a errores grandes) es de unas 7.5 unidades de ventas. La validación con división train/test (80/20) mostró un MAE de 5.83 y un RMSE de 7.52, lo que indica que, en promedio, el modelo de regresión lineal comete un error cercano a 6 unidades de ventas, con errores mayores en ciertos meses atípicos. Estos resultados sugieren que el modelo capta adecuadamente la tendencia general, aunque existen fluctuaciones que no logra explicar por completo.

```r
install.packages("Metrics")

# df1
set.seed(123)  # para reproducibilidad

df2_nn <- df2 %>%
  select(Fecha, `Ventas totales`) %>%
  na.omit()

# División 80% train, 20% test
n <- nrow(df2_nn)
train_index <- sample(1:n, size = 0.8*n, replace = FALSE)
```

```r
train_data <- df2_nn[train_index, ]
test_data  <- df2_nn[-train_index, ]

# Modelo de regresión lineal en train
modelo_train <- lm(`Ventas totales` ~ Fecha, data = train_data)

# Predicción en test
predicciones <- predict(modelo_train, newdata = test_data)

# Métricas de error
library(Metrics)
mae_val <- mae(test_data$`Ventas totales`, predicciones)
rmse_val <- rmse(test_data$`Ventas totales`, predicciones)

mae_val; rmse_val
```

```
## [1] 11.0482
```

```
## [1] 18.77981
```

En promedio, el modelo se equivoca en 11 unidades de ventas al hacer predicciones sobre los datos de prueba. El error cuadrático medio refleja que los errores grandes tienen más peso; este valor relativamente bajo indica que el modelo no está cometiendo errores extremos en exceso. La validación con división train/test (80/20) mostró un MAE de 11.0482 y un RMSE de 18.7798, lo que indica que, en promedio, el modelo de regresión lineal comete un error cercano a 11 unidades de ventas, con errores mayores en ciertos meses atípicos. Estos resultados sugieren que el modelo capta adecuadamente la tendencia general, aunque existen fluctuaciones que no logra explicar por completo.

Evaluación de resultados para regresión

```r
# Modelo
modelo_train <- lm(`Total comercio minorista sin otros vehículos` ~
Fecha, data = df1)

# Predicciones
predicciones <- predict(modelo_train, newdata = test_data)

# Cálculo de métricas
r2_val <- summary(modelo_train)$r.squared

list(
  R2 = r2_val
)
```

```
## $R2
## [1] 0.5715493
```

El coeficiente de determinación indica que aproximadamente el 57% de la variabilidad de las ventas es explicada por el modelo. Lo cual sugiere que el modelo captura de forma adecuada de la tendencia general, sin embargo, presenta ciertas limitaciones para predecir variaciones específicas.

8 RESULTADOS Y DISCUSION

De los métodos probados, el enfoque no parametrico independencia de variables, es decir el análisis exploratorio frente a distribuciones no normales fueron los que funcionaron mejor. Estos métodos permitieron capturar dependencias significativas (ej. Mes y Canal de compra) que los modelos lineales no detectaban adecuadamente.
A continuación, se interpretarán los resultados en base a las preguntas que se plantearon inicialmente:
¿Qué productos se compran más online?
A partir de las ventas registradas en los canales digitales, se observa que las categorías con mayor peso corresponden a productos de tecnología y entretenimiento, seguidos por moda y accesorios. Esto concuerda con la tendencia de que los bienes de fácil distribución y bajo contacto físico son los más favorecidos en el comercio electrónico.

¿Qué departamentos compran más online?
El análisis por regiones/departamentos muestra que los de mayor densidad poblacional y conectividad digital concentran el mayor número de compras online. Esto sugiere que el acceso a infraestructura tecnológica y logística influye directamente en la adopción del comercio electrónico.

¿El consumo digital ha reemplazado el físico?
El cruce de variables entre ventas físicas y digitales revela que el consumo digital no reemplaza totalmente al físico, sino que lo complementa. El comercio físico aún mantiene relevancia en categorías como alimentos, bebidas y bienes de primera necesidad, mientras que el digital domina en productos no perecederos y de fácil entrega.

¿El estrato socioeconómico está relacionado con la compra digital y física?
La prueba de independencia (Chi-cuadrado) evidenció que sí existe una relación significativa entre estrato socioeconómico y canal de compra. Los estratos altos muestran mayor proporción en el canal digital, mientras que los estratos medios y bajos siguen prefiriendo la compra física, principalmente por limitaciones de conectividad, acceso a medios de pago digitales y confianza en la entrega.

9. Conclusiones y recomendaciones

Después de un análisis exhaustivo de los datos de comercio digital y físico en Colombia, se pudieron llegar a las siguientes conclusiones:
•Los departamentos con mayor urbanización y conectividad concentran la mayor parte de las ventas online.
•El consumo digital complementa al físico, pero no lo reemplaza.
•El estrato socioeconómico influye significativamente en el tipo de canal de compra, con predominancia digital en estratos altos.
•Los productos más comprados online son los de tecnología, moda y entretenimiento.
Por otro lado, las limitaciones que identificamos a lo largo del desarrollo del presente informe son:
•El tamaño de la muestra en algunos estratos y categorías fue reducido.
•Los datos abarcan un periodo limitado, lo cual puede ocultar tendencias de largo plazo.
•No se incluyeron variables externas (como acceso a internet o confianza en medios de pago) que también influyen en la decisión de compra.
Finalmente, se recomienda ampliar la recolección de datos en regiones menos representadas para mejorar la robustez del análisis. También la inclusión de variables relacionadas con conectividad digital y hábitos de consumo para entender mejor la transición entre lo físico y lo digital. Todo esto con el fin de diseñar estrategias de inclusión digital enfocadas en estratos bajos para aumentar su participación en el comercio electrónico.